v0.7 Decoder：按原题交付物评分的 rubric v1

日期：2026-10-16。范围：已有九次尝试，七份科学交付；原题 prompt 哈希见 standard-answer.md。

1. 评分性质与边界

这是用户本轮要求建立的事后本地百分制，不是 SciCode 官方权重，也不是原运行前冻结的评分器。保留既有 pass/fail/unknown 判断与原 score 文件。本版量化便于比较完成程度，不把总分阈值冒充科学正确性或正式难度校准。A/B 难度条件仍未完成。

主要分数按原题 R1-R4 和明确 deliverables 组成，总计 100 分。原题允许 unresolved 加有效 bounds，不因诚实保留未知直接扣分；原题未指定算法，正确替代方法同等接受。R3 较小的有效 N0 单独作为成果强度比较，不把有效但较大的 N0 判为证明失败。

通用比例锚点：0= 缺失或核心错误；约 25%= 只有片段；约 50%= 实质完成但明显缺口；约 75%= 多数完成、有具体保留；100%= 该项要求有充分证据。允许半分或四分之一分，必须写理由和证据定位。不重复扣同一缺陷：例如近似偏差宣称主要扣 A3，D 项只评价规定小尺寸 API。

基础设施失败记 unknown/NA，不填科学零分。不完整交付与无参考答案也要区别。每条评分同时记录：提交中实际写出什么、独立检查支持什么、仍未知什么。评审补出的新证明不能冒充 AI 原提交已完成。

2. 主评分表：100 分

ID	满分	对应要求	满分证据及主要扣分点
A1	5	R1 覆盖	O0/O1/O2 各 N=2,...,8 共 21 条，区间/不确定性或有依据 unresolved；缺项扣对应覆盖
A2	8	R1 相判定依据	增长二维尺寸、概率覆盖、统计和外推足以支持所下判定；慢下降/似平台不单独决定零/正极限；定理可直接支持相区，不强制为定理重做 MC
A3	8	R1 误差控制	分开报告统计、有限尺寸和近似误差，数值误差估计有依据；chi 差不冒充真偏差上界。A2 已扣的中心极限推断缺口不在这里重复扣
A4	5	R1 图与判定语义	区分严格充分界、严格不可解码、数值边界和未知；不把界根当真实相变；图表与 answers 一致
A5	4	R1 结构一致性	相区判定与信息包含/等价类相容，必要时继承子集；合理处理 N4 异常与不对称；不要求每条单独充分界都严格嵌套
B1	4	R2 模型/几何	正确噪声、观测条件独立、边界、binary 成功条件；无偷看隐藏信息或替换噪声信道
B2	4	R2 信息顺序	O2 到 O1 到 O0 退化、风险/可解码集合包含；如使用跨 N 顺序需真正证明
B3	5	R2 charge 等价	O1(N2)=O0，N3=N6，N5=N7=N8 完整整数 q，N4 独立类；只要求证明作答依赖的关系，不奖励错误的全 N 单调性
B4	2	R2 特殊 rank	使用的 irrep 概率与小 N 例外正确，尤其 SU2 及 N4 determinant coincidences；避免 O2(N2)=O0 误判
C1	3	R3 statement	明确整数 N0、所有 N>=N0 和所有 p、L 趋无穷的风险结论；计算域和端点完整
C2	5	R3 见证/decoder	合法辅助规则及可行见证，或等价有效的直接 Bayes/posterior 论证；失败到贯穿分量及所需条件有效，避免把隐藏误当充分条件
C3	6	R3 相关性	合法处理共享边取向、侧边/chord 及 readout 条件独立；矩阵、随机粗粒化、分部 Cauchy-Schwarz 等有效替代同等接受
C4	4	R3 指数界与认证	固定路径概率、路径数、长度下界、全 p 严格因子 <1 和有限前因子；仅数值优化未认证全局最大需保留
C5	2	R3 结论范围	清楚充分 N0 不是最小/相界，r>=1 不是不可解码；证据可复核；更小 N0 另列成果强度

ID	满分	对应要求	满分证据及主要扣分点
D1	6	R4 联合 partition sum	保留同一边两端共享取向，正确局部概率和逻辑 sector；不是把顶点取向独立化或求 MAP 代替 sector posterior
D2	3	R4 精确算法	L<=4,N<=8 按要求精确或认证，解释收缩/枚举及复杂度；较大 L 近似不污染小尺寸承诺
D3	5	R4 独立核验	与不复用同一核心错误的独立枚举/参考比较，规定精度和 coverage 有证据；保留已有外部 heldout 检查的限定
D4	3	R4 数值范围	正概率记录不因下溢被误判零，规范化/log/高精度与端点可用；平台差异与原环境缺口分开
D5	3	decode 接口	返回合法边集合，syndrome 正确，逻辑决定与所用 posterior 规则相容；异常和非法输出可定位
E1	4	answers.json	结构、21 条目、端点误差/未解形式、R3_N0 与报告一致
E2	3	报告/图	有相图、R2/R3 证明、证据与局限，文件可找到；不按图的个人审美扣科学分
E3	3	源码/复现/资源	API、依赖环境、命令、seed/资源说明支持复现；8CPU/32GiB/无 GPU 要求有记录
E4	5	数据/无条件记账	原始数据、seed、停止规则、trial 分母、异常/非法输出计失败；预留 slots 与实际执行区分

小计：R1=30，R2=15，R3=20，R4=20，交付/可复现 =15。

3. 科学通过条件不由总分代替

R1：确切未知可以保留；但关键确定相判定没有足够证据、或把近似差当真误差界，不能靠其他项高分变成通过。

R3：核心见证、相关性或全 p 严格界有致命缺口，则本要求未满足；有效更大 N0 仍通过。原提交算术证据与评审后独立修补分别列明。

R4：必须满足题面小尺寸精度与接口。常规 heldout 通过不等于整个正概率输入域已证明稳健；压力缺口注明工程性质和平台。不可把这类易修复问题单独当 SciCode 所追求的科学判断失败。

整题：主要求逐项审阅，允许有保留/部分完成/unknown；不设事后 80 分自动及格线。没有 guided B，不形成正式 A/B 难度结论。

4. 讨论细节诊断：不额外计入 100 分

以下用于回答 “每个细节 AI 有没有做到位”。每 run 逐项标记 E= 明确正确论述，I= 隐含或只部分展开，M= 未见讨论，X= 明确错误/证据不足的推论，NA= 有效替代方法不需要，U= 没有科学交付。M 不自动等于原题失败，X 需要给出具体命题和定位。

ID	诊断问题	与原题关系
Q01	D_r(N) 定义为全 p 集合，信息更多则不缩小但不必严格扩大	R2 核心含义
Q02	N5 已恢复完整整数 q，N>=7 严格饱和，N6 例外	R2 核心
Q03	mod4 和 mod6 不互相包含，不能全 N 排序	使用跨 N 比较时必要
Q04	单独充分界不嵌套不等于真实相区违反信息顺序	R1 解释
Q05	把可靠 Z4 可解码子集转移给完整整数 q	R1/R2 一致性
Q06	Z4 纯三次与单次混淆、混合三次与单次混淆的区别	特征机制
Q07	高 p 活跃连通分量取向恒等式及其证明范围	可选增强分析
Q08	O1 中性对不可见与 O2 隐藏随 N 变稀少	R3/相图机制
Q09	X,C binary 与 sigma 潜取向分开，sigma 不提供给 decoder	模型核心

ID	诊断问题	与原题关系
Q10	差分分量自回避由度数 0/2 而来，非物理排斥	采用路径证明时必要
Q11	M 最小相容计数，11 才强迫真实隐藏，01/10 不改数量	采用该粗约束时必要
Q12	隐藏必要非充分，且对指定辅助 decoder 成立	采用隐藏证明时必要
Q13	decoder 评分/最少最多边数/Chernoff 条件参与概率界	相应证明路线必要
Q14	取向矩阵状态和每个元素解释正确	直接矩阵路线适用；替代路线 NA
Q15	占据矩阵与取向矩阵是不同状态空间	两矩阵路线适用；替代路线 NA
Q16	路径外边/chord 共享不能逐顶点独立重抽	相关性核心；合法避开可 E
Q17	R*<=R_aux 为平均风险比较，指数界不是临界指数	证明结论核心
Q18	partition function 保留全局取向，小尺寸 exact 与大尺寸 MPS 分开	R4 核心
Q19	相图估计/充分界/未知、统计/有限尺寸/近似不确定性分开	R1 核心
Q20	所有异常计失败，预留 slots 不充作已完成 trial	明确交付要求
Q21	用图逐格解释 sigma、F、首尾求和	本次讨论新增教学请求；原题非必答

本聊天中把矩阵索引 a,b 与 arrival 数 a,b 混用，是评审解释的符号失误；不能记成七份 AI 原提交的共同错误。参考答案改用 alpha,beta 与 n_V,n_barV。

5. 保存和复核

scores-v1.json 保存权重、每项得分、理由、证据和诊断；scores-v1.csv 便于排序；scorecards.md 面向人工审阅。所有原始 run 目录只读。审阅新增结论与既有评审差异均单列，不覆盖旧 scores.json。这里的细分权重可供下一批新测试事先冻结，当前批次只能称事后细分评审。

九次尝试的逐项评分与讨论细节审计 v1

本表是事后本地完成度评分，不是官方 SciCode 权重或事先冻结评分器。总分不替代 R1-R4 科学通过条件。七份科学交付与两份 API 失败均保留。

1. 总览

Run	R1 /30	R2 /15	R3 /20	R4 /20	交付 /15	总分 /100	N0	科学判断
Fable03	26	15	19.5	18	14	92.5	19	部分完成：中心相区证据与数值范围有缺口
Opus01	22	15	20	18	14.5	89.5	15	部分完成：中心外推、近似保证与数值范围有缺口
Opus02	22	15	20	18	14.5	89.5	15	部分完成：中心外推、近似保证与数值范围有缺口
Opus03	22	15	19	18	14.5	88.5	15	部分完成：同上；原全 p 算术认证另有保留
GPT01	30	15	20	20	15	100	13	按原题允许的保守作答暂定通过
GPT02	30	15	20	20	15	100	13	按原题允许的保守作答暂定通过
GPT03	29	15	20	20	15	99	14	有保留暂定通过：小 N 全 p 数值外推
Fable01	NA	NA	NA	NA	NA	NA	NA	API 输出限制，无法科学评审
Fable02	NA	NA	NA	NA	NA	NA	NA	API 输出限制，无法科学评审

GPT01/02 的 100 表示本 rubric 下满足原题允许的有限结论，并不表示真实全相图已解决。七份均完成高质量核心理论和常规后验，故部分完成者也可得较高完成度分；关键科学缺口不被总分掩盖。更小有效 N0 作为成果强度另列。

R3 按原提交计分：Fable03 与 Opus03 分别在全 p 算术认证完整性上保留 0.5 和 1 分；已有独立有理数复核支持其定理，不能说它们的 N0 结论已被推翻。

2. 23 项分数矩阵

项目	满分	Fable03	Opus01	Opus02	Opus03	GPT01	GPT02	GPT03
A1 R1 覆盖	5.0	5	5	5	5	5	5	5
A2 R1 相判定依据	8.0	4	5	5	5	8	8	7
A3 R1 误差控制	8.0	8	3	3	3	8	8	8
A4 R1 图与判定语义	5.0	5	5	5	5	5	5	5
A5 R1 结构一致性	4.0	4	4	4	4	4	4	4
B1 R2 模型/几何	4.0	4	4	4	4	4	4	4
B2 R2 信息顺序	4.0	4	4	4	4	4	4	4
B3 R2 charge 等价	5.0	5	5	5	5	5	5	5
B4 R2 特殊 rank	2.0	2	2	2	2	2	2	2
C1 R3 statement	3.0	3	3	3	3	3	3	3
C2 R3 见证/decoder	5.0	5	5	5	5	5	5	5
C3 R3 相关性	6.0	6	6	6	6	6	6	6
C4 R3 指数界与认证	4.0	3.5	4	4	3	4	4	4
C5 R3 结论范围	2.0	2	2	2	2	2	2	2
D1 R4 联合 partition sum	6.0	6	6	6	6	6	6	6
D2 R4 精确算法	3.0	3	3	3	3	3	3	3
D3 R4 独立核验	5.0	5	5	5	5	5	5	5
D4 R4 数值范围	3.0	1	1	1	1	3	3	3
D5 decode 接口	3.0	3	3	3	3	3	3	3
E1 answers.json	4.0	4	4	4	4	4	4	4
E2 报告/图	3.0	3	3	3	3	3	3	3
E3 源码/复现/资源	3.0	3	3	3	3	3	3	3
E4 数据/无条件记账	5.0	4	4.5	4.5	4.5	5	5	5

3. 我们讨论的 21 项细节

E= 明确正确；I= 隐含/部分展开；M= 未见；X= 具体错误或证据不足推论；NA= 合法替代路线无需此项；U= 无科学交付。教学图是后来新增要求，不追扣原任务分。

细节	Fable03	Opus01	Opus02	Opus03	GPT01	GPT02	GPT03
D_r(N) 定义为全 p 集合，信息更多则不缩小但不必严格扩大	E	E	E	E	E	E	E
N5 已恢复完整整数 q，N>=7 严格饱和，N6 例外	E	E	E	E	E	E	E
mod4 和 mod6 不互相包含，不能全 N 排序	E	E	E	E	E	E	E
单独充分界不嵌套不等于真实相区违反信息顺序	I	I	I	I	E	E	I
把可靠 Z4 可解码子集转移给完整整数 q	I	I	I	I	E	E	I
Z4 纯三次与单次混淆、混合三次与单次混淆的区别	I	I	I	E	E	I	I
高 p 活跃连通分量取向恒等式及其证明范围	M	M	M	E	E	M	M
O1 中性对不可见与 O2 隐藏随 N 变稀少	E	E	E	E	E	E	E
X,C binary 与 sigma 潜取向分开，sigma 不提供给 decoder	E	E	E	E	E	E	E
差分分量自回避由度数 0/2 而来，非物理排斥	E	E	E	E	E	E	E
M 最小相容计数，11 才强迫真实隐藏，01/10 不改数量	I	I	I	I	E	E	E
隐藏必要非充分，且对指定辅助 decoder 成立	E	E	E	E	E	E	E
decoder 评分/最少最多边数/Chernoff 条件参与概率界	E	E	E	E	E	E	E
取向矩阵状态和每个元素解释正确	NA	NA	NA	NA	E	E	NA
占据矩阵与取向矩阵是不同状态空间	NA	NA	NA	NA	I	E	NA
路径外边/chord 共享不能逐顶点独立重抽	E	E	E	E	E	E	E
R*<=R_aux 为平均风险比较，指数界不是临界指数	E	E	E	E	E	E	E
partition function 保留全局取向，小尺寸 exact 与大尺寸 MPS 分开	E	E	I	E	E	E	E
相图估计/充分界/未知、统计/有限尺寸/近似不确定性分开	I	X	X	X	E	E	E
所有异常计失败，预留 slots 不充作已完成 trial	X	X	X	X	E	E	E
用图逐格解释 sigma、F、首尾求和	M	M	M	M	M	M	M

NA 不表示没有处理相关性：Fable/Opus/GPT03 采用合法替代证明。I/M 也不自动表示题面失败；比如高 pZ4 恒等式和逐格教学图是增强解释。Q20 的 X 需按潜在实现缺陷与已发生异常分别阅读逐 run 证据。

4. 对先前评语的修正

七份均正确分析了 N5 完整整数 q 和 N>=7 饱和，不能把此事说成普遍遗漏。GPT01 与 Opus03 给出了 Z4 活跃连通分量恒等式。单独充分界不嵌套，不说明真实最优相区违背信息包含。

旧 REPORT 把三份 Opus 的中心解释概括得过宽：Gaussian/BKT 风险下界排除论证明确属于 Opus02/03；Opus01 应描述为典型 charge 钉扎 clean-loop 临界相的物理解释和慢漂移外推。此处修正归因，不改写历史原文件。

七份每份 210 个常规 posterior/correction 全部通过，其中 140 个是题面 R4、70 个 O0 控制。18 个极低 p 压力输入，GPT 通过，其他四份本机失败；Opus02 的 Linux/macOS longdouble 范围差异需保留。

Fable03 异常回退到 posterior=.5 会少计失败，但归档异常数为 0，是潜在缺陷；Opus 把 hard failure 记 1，但 posterior 风险仍用.5。GPT03 的 340600 是归档 slots，含 200 个预留保守失败 slots，不能称全部已完成物理 trial。

附录：扣分与保留项的证据定位

全部 161 项科学交付评分、21 项讨论诊断及完整绝对路径保存在 scorecards.md、scores-v1.json 和 score-details-v1.csv。下列集中列出改变得分或结论的项目。

Fable03

- A2：4/8.0。有增长二维尺寸的精确后验数据，但中心 charge 正风险相判定来自 L<=12 的慢漂移/正极限拟合，且未排除很长 crossover。原文：`anthropic__claude-fable-5-1/run_03/report.md:213`。
- C4：3.5/4。原交付的全 p 严格算术认证有保留；已有独立有理数复核支持定理。原文：`anthropic__claude-fable-5-1/run_03/docs/theory.md:224`。
- D4：1/3。210/210 常规通过；18 个极低 p 正概率压力案例未通过。具有普通逐步归一化，但局部乘积/边权仍可下溢。原文：`anthropic__claude-fable-5-1/run_03/src/model.py:198`。
- E4：4/5。种子、固定 job 数、资源、原始数组和分母均保存；但异常变 P0=.5，聚合按风险及 hard tie 均记.5，而题面要求异常为失败。data/summary.csv 总 nfail_exc=0，因此这是潜在缺陷，未见影响归档估计。原文：`anthropic__claude-fable-5-1/run_03/src/run_mc.py:56`。
- 异常记账缺陷是潜在问题；归档 summary 的异常计数总和为零，未发现它改变归档相图数值。

Opus01

- A2：5/8.0。二维尺寸到约 L48，诊断有价值；中心 charge 零极限与 clean-loop 相被 charge 钉扎的解释仍未排除其他正极限。原文：`anthropic__claude-opus-5-5/run_01/report.md:326`。
- A3：3/8.0。chi 对比和误差分类有工作量，但两个近似接近不能充当真 posterior 偏差的上界。原文：`anthropic__claude-opus-5-5/run_01/report.md:82`。
- D4：1/3。210/210 常规通过；18 个极低 p 正概率压力案例未通过。具有普通逐步归一化，但局部乘积/边权仍可下溢。原文：`anthropic__claude-opus-5-5/run_01/solution.py:71`。
- E4：4.5/5。原始数据、种子、固定块停止规则、资源和所有尝试分母有记录，bad hard failure 为 1；但报告的 posterior-min 风险遇异常仍设.5 而不是 1。原文：`anthropic__claude-opus-5-5/run_01/src/mc.py:146`。

Opus02

- A2：5/8.0。二维尺寸到约 L96；Gaussian/BKT 启发式未被证明足以排除题目后验模型的所有不可解码相。原文：`anthropic__claude-opus-5-5/run_02/REPORT.md:184`。
- A3：3/8.0。将 chi 与更大 chi 之差提升为 induced bias 上界，缺少对后者误差的控制。原文：`anthropic__claude-opus-5-5/run_02/REPORT.md:301`。
- D4：1/3。210/210 常规通过；18 个极低 p 正概率压力案例未通过。具有普通逐步归一化，但局部乘积/边权仍可下溢。macOS longdouble 范围与原 Linux 不同，不能把全部 macOS 失败直接归因于原环境；但 pri 中 p/2 在 Python float 转 dtype 前归零，在最小正 float 处跨平台存在。原文：`anthropic__claude-opus-5-5/run_02/hexsym/api.py:45`。
- E4：4.5/5。原始数据、种子、固定块停止规则、资源和所有尝试分母有记录，bad hard failure 为 1；但报告的 posterior-min 风险遇异常仍设.5 而不是 1。原文：`anthropic__claude-opus-5-5/run_02/hexsym/sim.py:49`。
- 极低 p 数值缺口包含原 Linux 与复核 macOS 的 longdouble 范围差异；Python float 先算 p/2 的最小 subnormal 问题不依赖此差异。

Opus03

- A2：5/8.0。二维尺寸到约 L64；慢下降和 Gaussian/BKT 排除不足以确定中心 charge 零极限。原文：`anthropic__claude-opus-5-5/run_03/report.md:239`。

- A3：3/8.0。较大 chi 也可能有共同偏差，经验收敛差不能提供所声称的真偏差保证。原文：`anthropic__claude-opus-5-5/run_03/report.md:355`。
- C4：3/4。原交付的全 p 严格算术认证有保留；已有独立有理数复核支持定理。原文：`anthropic__claude-opus-5-5/run_03/docs/proofs.md:199`。
- D4：1/3。210/210 常规通过；18 个极低 p 正概率压力案例未通过。具有普通逐步归一化，但局部乘积/边权仍可下溢。原文：`anthropic__claude-opus-5-5/run_03/symdec/api.py:43`。
- E4：4.5/5。原始数据、种子、固定块停止规则、资源和所有尝试分母有记录，bad hard failure 为 1；但报告的 posterior-min 风险遇异常仍设.5 而不是 1。原文：`anthropic__claude-opus-5-5/run_03/symdec/mc.py:121`。

GPT01

本 rubric 主项均满足。仍按参考答案保留中心相区未知，不等于已求出全相图。

GPT02

本 rubric 主项均满足。仍按参考答案保留中心相区未知，不等于已求出全相图。

GPT03

- A2：7/8.0。增长二维精确后验支持小 N O2 的数值全 p 判定；有限网格与较晚 crossover 仍有保留，不是全 p 定理。原文：`openai__gpt-6-astra/run_03/report.md:3`。
- 归档 340600 slots 含 200 个未证实执行的预留失败 slots，报告中按此限定解读。

附录：版本和复核范围

原 prompt SHA-256：`d89b765a4af1e50b2824d40d0c2d8590e722202219411bd49f5ea7d63c64d6a9`。不改题、不启动新模型或生产相图实验。复用已有独立 oracle、210 例常规检查、18 例压力检查和大 N 有理数证书；本轮新增 rubric、交付物细分审计及参考安全端点认证。

评分不是正式 SciCode A/B 难度结论。完整官方模板仍未获验证，本地权重不冒充官方规定。总分是完成程度，关键科学通过条件逐项保留。