“层状钙钛矿块氧化物的半填充态”题目
十一份 AI 答卷的评分报告

评分人：Claude（Fable 5.1）
出题人：游亦庄（UC San Diego / EdenCode）

2026 年 10 月 31 日

摘要

本报告对基准题目 *A layered oxide built from perovskite-type blocks —low-temperature state of matter at half filling*（文件夹 `lattice-gap-mechanism`）的十一份答卷给出评分和逐份评判。答卷来自四个模型：Anthropic Claude Opus 5.5（三份）、Claude Fable 5.1（三份）、OpenAI GPT-6 Astra（三份）、OpenAI GPT-6.1 Sol（两份）。所有答卷拿到的是 2026-10-30 以前的题目版本（见 1.1 节）。第一章给出总览、总表、各考点的通过情况和双层/SMG 的来源分析；第二章对每一份答卷逐一评判，引用原文和图作为依据；第三章是结语。全部分数为百分制，五道小题各 20 分。

目录

1 总览 **3**

1.1 题目、标准答案与答卷看到的数据版本 3
1.2 总表 4
1.3 容易做对的考点 5
1.4 容易出错、表现不好的考点 5
1.5 各考点的通过情况 6
1.6 双层和“SMG”是怎么来的 6

2 逐份评判 **9**

2.1 Claude Opus 5.5，`run_01`（91 分） 9
2.2 Claude Opus 5.5，`run_03`（83 分） 12
2.3 Claude Opus 5.5，`run_02`（57 分） 15
2.4 Claude Fable 5.1，`run_01`（57 分） 17
2.5 Claude Fable 5.1，`run_02`（51 分） 19
2.6 Claude Fable 5.1，`run_03`（49 分） 21
2.7 GPT-6.1 Sol，`run_02`（47 分） 22
2.8 GPT-6 Astra，`run_01`（46 分） 24

2.9 GPT-6 Astra，`run_02` 与 `run_03`（各 32 分） 25
2.10 GPT-6.1 Sol，`run_01`（30 分） 27

3 结语：这批答卷说明了什么 **29**
3.1 分数的分布是由一个决定造成的 29
3.2 保守是这批模型的默认姿态 29
3.3 “知道 SMG”和“推出双层”是两件事 29
3.4 真正算过的答卷彼此一致，没算过的答卷彼此分歧 30
3.5 答卷反过来纠正了题目 30
3.6 对出题和评分的启示 30

1 总览

1.1 题目、标准答案与答卷看到的数据版本

题目给解题者一份 `prompt.pdf` 和 `measurements.json`：一个由钙钛矿型块构成的层状氧化物，三块晶体（$\nu = 1/2$、$\nu \approx 0.3$、$\nu \approx 0.2$），四条 STS 微分电导、三条 NMR $1/(T_1T)$、三条面内电阻率，外加衍射和 NMR 单线的文字陈述。五道小题分别要求：(1) 最可信的有效理论及其哈密顿量的每一项、系数和不确定度；(2) ν–T 相图及三块晶体由低温到高温的相序；(3) 用该理论逐一解释每组数据；(4) 三个填充下低温 ARPES（除以费米函数）的密度图及其物理含义；(5) 由 $\nu = 1/2$ 的谱经 Kramers–Kronig 得到 $\omega = 0$ 处 Green 函数零点的闭合曲线，以及它所包围的布里渊区份额，并与 ν 比较。

出题方的生成模型是双层正方格子 t–t'–$J_\perp$ 模型：$t = 1.00\,D$，$t' = 0.20\,D$，$t_\perp \approx 0$，$U \approx 0$，$J_\perp = 8\,D$。半填充时每个 rung 形成层间自旋单态，是无序参量、不破缺任何对称性的绝缘体（对称质量生成，SMG）；掺杂后形成层间单态 s 波超导，$\nu \approx 0.3$ 偏 BEC（T_c 远低于配对温度），$\nu \approx 0.2$ 偏 BCS。第 1 题的关键推理链是 Lieb–Schultz–Mattis（LSM）：一个轨道占主导、面内一个金属位点一个原胞、半填充、完全对称且有能隙 $\Rightarrow$ 原胞里必须有两个等价的过渡金属位点，即钙钛矿双层块。

数据版本。 十一份答卷拿到的是 2026-10-28 的版本：$\nu \approx 0.2$ 的 $T_c = 1.11\,D$（等于平均场配对温度），$\nu \approx 0.2$ 的 NMR 带 Hebel–Slichter 峰，$\nu = 1/2$ 的电阻率是纯激活型，图 (a) 用领头阶两极谱（$\varepsilon(k)/2$ 色散，能隙 7.99，Eq. (19) 残差）。此后出题方根据这批答卷暴露的问题做了修订（2026-10-30/31）：$T_c(0.2)$ 降为 $0.40\,D$ 以满足二维刚度上界，$\nu \approx 0.2$ 的 NMR 改为赝能隙型，半填充电阻率改为 Boltzmann 曲线，掺杂电阻率加 Halperin–Nelson 尾，$\nu = 1/2$ 的低温窗口加了一句“电阻一直升到 $0.05D$、无新衍射峰”，并在 10-31 把图 (a) 换成 3×3 团簇 ED 标定谱（能隙 8.6，两侧带宽 2.7/3.0，第 5 题 key 0.87）。本报告中引用答卷的数字时，一律以答卷当时看到的旧数据为准；凡答卷的判断在新版本下会改变的，在相应位置注明。

1.2 总表

答卷	所写模型	1	2	3	4	5	**总分**
Opus 5.5 `run_01`	双层 t–t'–$J_\perp$–U（$J_\perp = 6.6, U = 1.4$），经 LSM 推出双层	19	17	18	18	19	**91**
Opus 5.5 `run_03`	双层 t–t'–$J_\perp$（$J_\perp = 8.0, U \approx 0$），经 LSM 推出双层，命名为 SMG	18	16	17	16	16	**83**
Fable 5.1 `run_01`	单层吸引 U，$U_{\text{eff}}(\nu) = 12/8.5/6$	7	10	11	13	16	**57**
Opus 5.5 `run_02`	单层吸引 U，$U_{\text{eff}}(\nu) = 12/8/6$	7	10	11	13	16	**57**
Fable 5.1 `run_02`	单层排斥 $U = 12$ + 独立配对 $V = 6$	5	9	9	13	15	**51**
Fable 5.1 `run_03`	单层排斥 $U = 12$ + 独立配对 $g = 6.1$	5	9	9	12	14	**49**
Sol `run_02`	有条件的两极“谱哈密顿量”，不选微观模型	9	5	9	8	16	**47**
Astra `run_01`	有条件的双层试探模型，“系数未被确定”	9	4	9	8	16	**46**
Astra `run_02`	单层 Hubbard“起点模型”，只给不唯一性构造	4	3	8	5	12	**32**
Astra `run_03`	同上（扩展 t–t'–U–J_1–J_2）	4	3	8	5	12	**32**
Sol `run_01`	单轨道 Hubbard $U = 11.5$ 的 8/10 格点 ED；撤回前一答卷	4	3	7	5	11	**30**

表 1: 十一份答卷的分项得分。每题 20 分。模型均值：Opus 5.5 为 77，Fable 5.1 为 52，GPT-6 Astra 为 37，GPT-6.1 Sol 为 38。

答卷	主要问题（一句话）
Opus `run_01`	近乎完整；$J_\perp$ 偏低（6.6 对 8），用三维耦合解释 $T_c(0.2) = 1.11$ 超出二维刚度上界（这一点后来证明是题目的错）。
Opus `run_03`	完整但停留在领头阶强耦合；第 5 题用等残差得 0.315，$\mathrm{Re}\, G(\Gamma, 0)$ 的符号与团簇精确解相反；相图的 BCS/BEC 边界是人为陡降。
Fable `run_01`	单层吸引 U，靠 U_{eff} 随掺杂变化（12→8.5→6）拟合三块晶体，不是一个哈密顿量；把半填充配对序推到测量窗口之下来规避 LSM。
Opus `run_02`	与 Fable `run_01` 同一条路；明确写出了 LSM 对 Cooper 对的约束，却用“预言 $T < 0.08D$ 超导”来满足它。
Fable `run_02`	单层排斥 Hubbard，自旋能隙 5.5 靠 (π, π) 超精细形状因子解释；需要第二个无关的 $6D$ 配对相互作用。
Fable `run_03`	同上；第 5 题在 $\omega = 0$ 处无零点曲线（Hubbard-I 型平坦零点带）。
Sol `run_02`	拟合极精细，发现了两处题目缺陷（二维刚度、(c) 的粒子数方程），但拒绝给出微观模型和相图。
Astra `run_01`	搜到了出题人自己的双层单态文献，仍写“双层是模型假设而非数据结论”；$\nu \approx 0.3$ 的 ARPES 画成水平连续谱作反例。
Astra `run_02`, `run_03`	只做不唯一性构造，不选模型、不画相图、不预测谱。
Sol `run_01`	把前一答卷撤回，做了严谨的单轨道 Hubbard 审计，结论是“未获得联合解”。

表 2: 每份答卷的主要问题。

1.3 容易做对的考点

动力学部分几乎不区分答卷。十一份答卷全部从图 (d) 读出 $t = 1.00 \pm 0.01$、$t' = 0.20 \pm 0.01$ 和 $\mu(0.3) = -0.91$，并核对占据份额为 0.30；全部读出半填充能隙 8.0、自旋激活 5.5、输运激活 3.7、两个 T_c 的区间，以及 $\nu \approx 0.2$ 的 Hebel–Slichter 峰和 $\nu \approx 0.3$ 没有该峰。八份答卷（三份 Opus、三份 Fable、Sol `run_02`、Astra `run_01`）明确认出图 (a) 的两个带是母带的平移（不是镜像）半宽副本，并把 (c) 拟合成母带上 $\Delta = 1.96$ 的各向同性 BCS 态；其中六份用 (c) 的能隙反推出配对耦合 $V \approx 6$。没有一份答卷引用了命名化合物的文献参数，这一点各家都做到了。

第 5 题的“为什么不是 $1/2$”也普遍答对：九份答卷指出 $t' \neq 0$ 破坏粒子–空穴对称，零点曲面不受定理保护，且 $t' = 0$ 时恰为 $1/2$；六份答卷扫描了参考能量 ω_r，看到份额从 1 变到 0。

1.4 容易出错、表现不好的考点

1. **双层的推出**。这是整道题的分水岭，只有两份 Opus 答卷写出了 LSM 链并据此构造双层。三份答卷（Fable `run_01`、Opus `run_02`，以及部分地 Fable `run_03`）选单层吸引 U，用两种办法绕开 LSM：把 Cooper 对的序（CDW 或超导，能标 $2t^2/|U| \approx 0.17D$）放到最低测量温度 $0.45D$ 之下，并让 $|U_{\text{eff}}|$ 随掺杂从 12 变到 6。两份 Fable 选单层排斥 $U = 12$，则对 5.5 的自旋能隙无能为力（排斥 Hubbard 的自旋能标是 $4t^2/U = 0.33$），只能另加一个 $6D$ 的配对相互作用。五份 OpenAI 答卷不作选择。最强模型的单次成功率约三分之一。

2. **自旋能隙大于电荷激活**。$\Delta_s = 5.5 > \Delta_\rho = 3.7$ 是单层模型过不去的坎：吸引 U 里自旋和电荷由同一种准粒子携带，排斥 U 的自旋能标又太小。Opus `run_01` 把它画成图 6(b) 作为选模型的决定性证据；Fable `run_02` 用 (π, π) 形状因子把 4.0 拉到 5.4，是一个有创意但勉强的补丁。

3. **相图的可计算部分**。六份答卷画了带 $T_c(\nu)$、$T^*(\nu)$ 的相图，但 T_c 的掺杂依赖都是用一两个测量点校准的插值（指数 $p = 2.8$、$(1 - 2\nu)^3$ 之类），不是计算；OpenAI 的五份只画“测量约束图”。

4. **T_c 与二维相刚度**。四份答卷（Opus `run_01`、`run_02`、Fable `run_01`、Sol `run_02`）指出 $T_c(0.2) = 1.11D$ 超过严格二维模型的 BKT 上界（0.2–0.44），但 Anthropic 的答卷一律归咎于“层间三维耦合”，只有 Sol `run_02` 和 Sol `run_01` 把它当成数据与模型的矛盾。事后看，Sol 是对的：这是题目的错，已改。

5. **$\nu \approx 0.3$ 的谱**。没有一份答卷给出可控的计算。Opus 两份用“两个能标的 $\Delta(\xi)$”经验式，Fable 三份各有一套唯象形式（局域对自能、同向 Hubbard 型分支、Mott 压缩的 Bogoliubov 镜像带），Sol `run_02` 试了六个拟设全部失败后如实报告。这是题目里信息最少、也最难的一块。

6. **第 5 题的数值**。分布从“无曲线”到 0.035、0.075、0.081、0.14、0.315、0.46、0.855。原因不是算错，而是零点带只在能隙里色散 $\sim 1D$，$\omega_r = 0$ 落在哪一侧由残差的 k 依赖决定；领头阶两极谱加数据拟合的残差，与团簇精确解的符号往往相反（Opus `run_03`、`run_02`、Fable `run_02`、Sol `run_02`、Astra `run_01` 都得到 Γ 点 $\mathrm{Re}\, G < 0$，而 16 格点和 3×3 团簇的精确解是 $\mathrm{Re}\, G(\Gamma, 0) > 0$）。两份真正做了多体数值的答卷（Opus `run_01` 的 16 格点 CPT/ED：0.855；出题方 3×3 ED：0.82–0.87）彼此一致。

7. **拒答**。五份 OpenAI 答卷把“数据不足以唯一确定”当成最终答案，用大量篇幅构造反例，不给出可证伪的模型。它们的反例在数学上都是对的，但题目问的是“最可信的理论”，不是“唯一

可证明的理论”。

1.5 各考点的通过情况

考点	Opus r1	Opus r3	Fable r1	Opus r2	Fable r2	Fable r3	Sol r2	Astra r1	Astra r2	Astra r3	Sol r1
t, t', μ 由图 (d) 读出	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓	✓
图 (a) = 平移的半宽副本（非镜像）	✓	✓	✓	✓	✓	✓	✓	✓	○	○	–
图 (c) = 母带上的 BCS，$\Delta \approx 1.96$	✓	✓	✓	✓	✓	✓	✓	✓	○	○	–
注意到 $\Delta_s(5.5) > \Delta_\rho(3.7)$ 并处理	✓	✓	○	○	○	○	–	–	○	–	✓
写出 LSM 约束	✓	✓	–	✓	–	–	–	○	○	○	–
由 LSM 推出双层并采用	✓	✓	–	–	–	–	○	○	–	–	–
一个哈密顿量解释三块晶体	✓	✓	–	–	○	○	–	–	–	–	–
相图含计算的 $T_{\mathrm{MF}}/T_c/T^*$	✓	✓	✓	✓	✓	✓	–	–	–	–	–
指出 $T_c(0.2)$ 超二维刚度上界	○	○	○	○	–	–	✓	○	–	–	✓
(c) 的粒子数自洽（$\nu_{\mathrm{calc}} = 0.256$）	○	○	–	–	–	–	✓	✓	–	–	–
三张 ARPES 图有明确承诺	✓	✓	✓	✓	✓	✓	○	○	–	–	○
第 5 题：零点曲线 + 符号 + 扫描 + 原因	✓	✓	✓	✓	✓	○	✓	✓	○	○	○
第 5 题数值与团簇精确解同号	✓	–	–	–	–	–	–	–	–	–	○
指出 $t \to -t$ / (π, π) 平移的歧义	–	✓	–	–	–	–	✓	✓	–	–	✓
做了多体数值（ED/CPT）	✓	○	✓	○	–	–	–	–	–	–	✓

表 3: 考点通过表。✓：做到；○：部分做到或只提及；–：没有。“$\Delta_s > \Delta_\rho$”一行中 Sol r1 的 ✓指它用 10 自旋团簇证明排斥 Hubbard 的自旋响应比数据大五个量级。

1.6 双层和“SMG”是怎么来的

出题人特别关心：两份推出双层的 Opus 答卷是怎么推出来的，有没有上网查文献，以及 Opus `run_03` 为什么会知道“对称质量生成(SMG)”这个小众名词。我检查了全部十一份的 `trajectory.txt`（工具调用记录）。

没有一份 Anthropic 答卷上过网。 六份 Claude 答卷的工具列表里都有 `WebSearch` 和 `WebFetch`，但调用计数为零（Opus `run_01`：Bash 183 次、Read 30 次、Write 18 次、Edit 2 次；Opus `run_03`：Bash 69、Read 17、Write 11、Edit 6；其余类似）。轨迹里出现的全部 URL 是 pip 镜像。报告里引用的文献——Rosch (2007)、Dave–Phillips–Kane (2013)、Hazra–Verma–Randeria (2019)——都来自参数记忆。

Opus `run_01` 的推理链 （轨迹中“thinking”摘要和报告 §1.2、§2）：先拟合图 (d) 得母带；再发现图 (a) 两带是刚性平移（重叠 0.976，镜像只有 0.70）、半宽、权重 $\frac{1}{2} \mp \varepsilon_k/2E_{\mathrm{ex}}$；然后它自己写了无矩阵 Lanczos 代码，对单层排斥和吸引 Hubbard 做 10/16/20 格点 ED，得到吸引模型掺杂态的能隙 3.4–4.0（数据 1.96/2.85）、排斥模型无自旋能隙；此时轨迹第 3564 行写道：

> Finite-size data rule out both repulsive and attractive single-layer Hubbard models, and Lieb–Schultz–Mattis implies a fully gapped symmetric insulator needs two equivalent TM sites per cell (bilayer rung singlets), which matches the observed NMR/transport gaps. I'll build a bilayer ED code with interlayer exchange $J_\perp$ to test this.

报告里的表述是："If the primitive cell contained one TM, the LSM–Oshikawa–Hastings theorem would forbid a unique, gapped, fully symmetric ground state. The only way out would be topological order, with gaps bounded by the exchange scale ($\approx 4t^2/U \approx 0.3$), far below the measured 5.5 and 3.7. The data therefore require an even number of electrons per primitive cell, i.e. two crystallographically equivalent TM sites per cell. This is exactly what a perovskite bilayer block provides." 这条链是"先证伪单层，再用 LSM 逼出双层，再用 ED 验证双层"，三步都有数值依据，是所有答卷里最完整的。它随后用 ED 扫描的起点 $U \approx 12 - 1.5J_\perp$ 说明它知道两极分裂 $E_{\text{ex}} = U + 3J_\perp/2$ 的关系，但它从头到尾没有用"SMG"这个词，只叫"rung-singlet Mott insulator"。

Opus `run_03` 的推理链和 SMG 的来源。 这份答卷走的是解析路线：拟合图 (a) 得 $E_\pm = \pm\Phi + s(\varepsilon_k - \varepsilon_c)$，$\Phi = 6.011$，斜率 $s = 0.497$（"exactly 1/2"）；拟合图 (c) 得 $V = 5.992$。轨迹第 2504 行它第一次提出"renormalized bilayer (hopping $t/2$, rung splitting $\pm\Phi$) with interlayer pairing"，第 3035 行用两 rung ED 比较 $(U, J_\perp) = (0, 8)$ 和 $(3, 6)$ 的三重子能隙，第 3602 行写道：

> I've identified this as the symmetric mass generation bilayer model, where the half-filled ground state is a featureless rung-singlet insulator consistent with the observed hopping features.

报告正文把这个态称为"featureless rung-singlet insulator, also called a symmetric-mass-generation (SMG) insulator",并在对称性表里写"the η-pairing / pseudospin SU(2) and the enlarged SO(4)/SU(4) symmetries of some SMG models"。它用的公式 $\Phi = 3J_\perp/4 + U/2$、HFB 配对耦合 $V = 3J_\perp/4$、$\nu = 1/2$ 的 rung 对 Mott 绝缘体、掺杂后 $T_c \to 0$ 线性趋近半填充，都是 Lu–Zeng–You（arXiv:2307.12223）那篇文章的结构。它没有查网，这些内容来自训练语料：SMG 的系列文章（2017 年以来）和 2023 年的双层镍酸盐 SMG 文章都在 arXiv 上，而"半宽平移副本 + rung 单态 + 层间交换 + 掺杂 BEC 超导"这组特征在文献中几乎只对应这一个方向，模型做的是模式匹配。值得注意的是它只借了名字和公式框架，参数（$J_\perp = 8$、$U = 0$）是从数据拟出来的，而且它在系统误差里正确预言了高阶修正会把带宽从 4.0 压到 3.0、带中心从 6.0 降到 5.7——这正是 10-31 换图后的新数据。

Astra `run_01` 搜到了文献却没有用。 三份 Astra 答卷都大量上网（`run_01` 20 次搜索/打开）。`run_01` 的搜索词里有"symmetric mass generation Green function zeros Luttinger surface bilayer t J interlayer spin exchange"和"symmetric mass generation bilayer NMR resistivity spin gap doping pseudogap"，它打开了 arXiv:2308.11195 并在报告里写"See the bilayer singlet model of Lu and collaborators for a theoretical example"——也就是说它找到了出题人课题组的双层单态文章，还找了 Hastings 的高维 LSM（cond-mat/0305505）和 Rosch 的 Luttinger 定理失效（cond-mat/0602656）。然而它的结论是："A bilayer is a possible model assumption, not a fact established by these inputs. ... This is an established possible mechanism ...; it is not a deduction of the layer structure from STS."知识不是它的瓶颈，决策是。

小结。 “AI 怎么会知道 SMG”的答案是：它在预训练里读过这些 arXiv 文章，而题目数据的特征组合足够独特，让一个模型在无检索的情况下把它和那一小簇文献对上了。但知道名字和能推出双层是两件事：Opus `run_01` 不知道（或没提）名字却推出了双层；Astra `run_01` 搜到了文章却不肯推。

2 逐份评判

每一份按“模型与结论——推理链与证据——图——逐题评分——总评”的顺序写。引文均取自该答卷的报告文件（`REPORT.md`、`report.md`、`answer.md` 或 PDF），行号指报告文件；轨迹引文指 `trajectory.txt`。评判的参照是出题方的生成模型和答卷当时看到的数据（1.1 节）。

2.1 Claude Opus 5.5，`run_01`（91 分）

模型与结论。 双层 Hubbard–Heisenberg 模型：$t = 1.00 \pm 0.02$，$t' = +0.20 \pm 0.02$，$|t_\perp| < 0.2$，$U = 1.4 \pm 0.8$，$J_\perp = 6.6 \pm 0.5$。半填充态是“featureless, interaction-driven insulator of interlayer spin singlets (a ‘rung-singlet’ Mott insulator)”，无任何破缺、无拓扑序；掺杂态是层间单态 s 波超导，$\nu \approx 0.3$ 为预形成对的强配对态，$\nu \approx 0.2$ 为 BCS。第 5 题：零点曲线是 M 点周围的一个小闭合圈，Γ 一侧占 0.85 ± 0.03，$\mathrm{Re}\, G(\Gamma, 0) > 0$。

推理链与证据。 这份答卷的结构是“数据 → 证伪 → LSM → 构造 → 验证”，每一步都有数值：

- 图 (a)：“The two bands in Fig. 1(a) are rigid translates of each other. Their overlap after a shift of 12.1 ± 0.1 is 0.976; the overlap of the mirror image is only 0.70.”——这是区分平移副本与 Bogoliubov 镜像的定量判据，其他答卷只用了拟合残差。
- 自旋与电荷能标：“Spin excitations therefore cost more than the thermal charge carriers: $\Delta_s = 5.5 > \Delta_\rho = 3.7$, with $\Delta_s < E_g = 7.9$.”随后用这一点排除单层模型（报告 §2 表）：吸引 Hubbard 的 10/16/20 格点 ED 给掺杂能隙 3.4–4.0（数据 1.96、2.85），“Spin and charge excitations are the same quasiparticles, so it cannot give $\Delta_s > \Delta_\rho$”，“Pairs hop with $J \approx 4t^2/|U| \approx 0.33$ and would conduct for $T \gg J$, so $\rho(0.45)/\rho(4) \approx 1$, not 1600”，“The high-$T$ spectrum at $\nu = 0.3$ would carry Hubbard satellites holding 30% of the weight; they are absent in Fig. 1(d)”。这五条反驳每一条都对，而且恰好是选吸引 U 的三份答卷没有自查的地方。
- LSM（§1.2）：原文见 1.6 节。它还给出拓扑序的能标论证（“gaps bounded by the exchange scale $\approx 4t^2/U \approx 0.3$, far below the measured 5.5 and 3.7”），这是题目 rubric 要求的那一步。
- 验证：16 格点双层 ED，$(U, J_\perp) = (1.8, 6.5)$ 给半能隙 4.10（数据 3.95）、自旋能隙 4.72（数据 5.5）；扭曲边界条件算配对刚度 $D = 1.06/0.74/0.02$ per rung（$\nu = 0.19/0.31/0.5$），用来说明 $T_c \to 0$ at $\nu = 1/2$。

系数的确定方式（§3 表）有一处系统性偏差：$J_\perp$ 是四个估计的加权平均，其中“(iii) $T_c(0.2) = 1.11 = T_{\mathrm{MF}}$ requires $J_\perp = 6.45$”把旧数据里一个错误的数当成了约束，把 $J_\perp$ 从 NMR 给出的 7.1 拉到 6.6。它在 §9 其实已经看到了矛盾：“A strictly 2D model would give $T_{KT} \lesssim 0.3$ at $\nu = 0.2$. The measured T_c therefore implies three-dimensional coupling between bilayers”——这是把数据的错误归咎于模型之外的物理，而 Sol `run_02` 在同一处选择了相信模型。新版数据 $T_c(0.2) = 0.40$ 之后，这个约束消失，它的 $J_\perp$ 会回到 7–8。

图。 图 1 是它的四块 STS 对比。(a) 里 CPT 曲线的两个带比旧数据窄（约 3.0 对 4.0），峰位更靠内；它在 §9 写“the model’s spin gap (4.7) is about 15% below the NMR value”，却没有写“数据的

带比模型宽”——而后者恰恰是题目的问题。10-31 换成 ED 标定谱后，新图 (a) 的带宽 2.7/3.0、峰位 $-4.8/+6.1$、外侧弱肩，与这条 CPT 曲线几乎一样；它 ARPES 图（图 3）里 $\nu=1/2$ 的两条带 $-7.4\to-4.1$、$+4.1\to+7.0$ 和 ±9 附近的卫星，也与新数据的 $-7.3\to-4.3$、$+4.3\to+7.0$、±10 处的肩一致。这是“答卷比题目更对”的一例。图 2 的零点结构（Γ 红、M 蓝、零点带 -0.15 到 $+0.65$、份额随 ω_r 从 1 到 0）与出题方 3×3 团簇的精确值（Γ：$+0.025$，M：-0.011；零点带 $+0.82$ 到 -0.41）定性一致，16 格点周期团簇的精确 $G(K,0)$（$+0.027$、-0.013）与 3×3 几乎相同。相图（图 4）的形状正确：T_c 在 $\nu=1/2$ 归零、T^* 在半填充最高、两侧超导穹顶；但 $T_c(\nu)$ 是 $T_{\mathrm{MF}}\cdot\min[1,(Z/Z_{0.2})^{2.8}]$ 的插值，指数由一个测量点定，它自己也写了“This is an interpolation, not a calculation of T_c”。(b) 面板的拟合用了“两个能标的 $\Delta(\xi)$”（$\Delta_0=2.85$ 在 k_F，$\Delta_\infty=5.23$ 远离 k_F），形式是从数据反推的，不是算出来的。

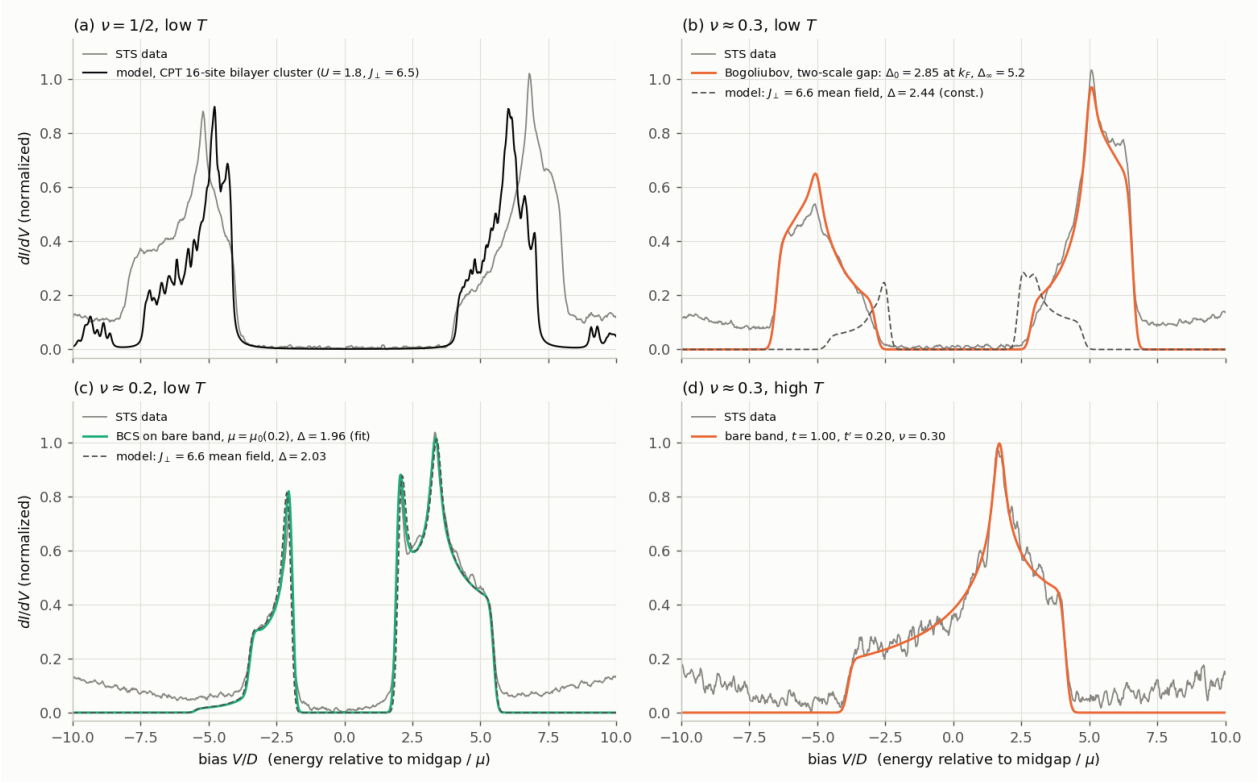


图 1: Opus `run_01` 图 1：STS 与理论。(a) 16 格点双层 CPT（黑）对旧数据（灰）：CPT 的带更窄、峰更靠内，这正是 10-31 换图后新数据的样子。(c) 母带上的 BCS 几乎到噪声水平。(b) 的橙线是数据拟出的两能标 $\Delta(\xi)$，虚线是 $J_\perp=6.6$ 平均场 $\Delta=2.44$，说明平均场在这个填充下不够。

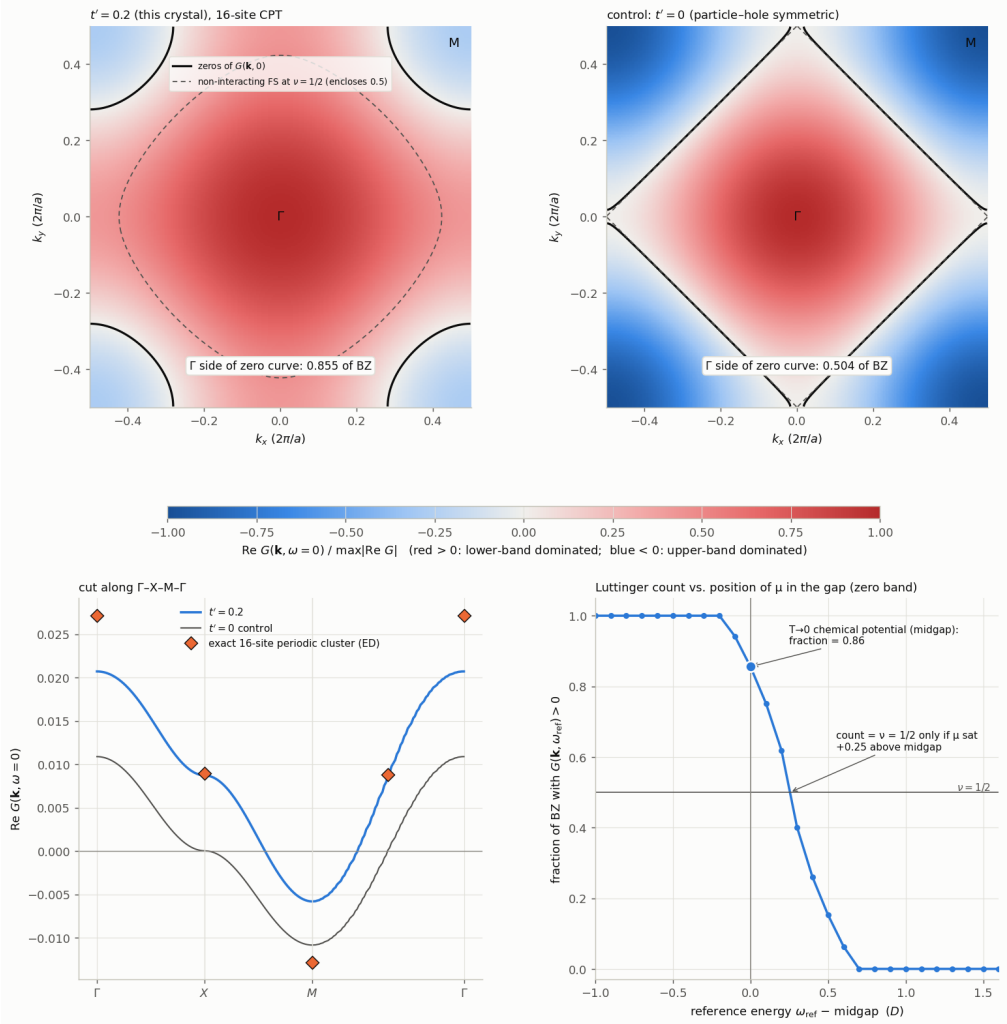


图 2: Opus run_01 图 5：第 5 题。左上：$t' = 0.2$ 的 $\mathrm{Re}\,G(k,0)$，零点是 M 周围的小圈，Γ 侧 0.855；右上：$t' = 0$ 的对照恰为 0.504；左下：沿路径的 $\mathrm{Re}\,G$ 与 16 格点精确团簇值（菱形）；右下：份额随参考能量扫描。这是十一份里唯一一份符号、数值、扫描都与出题方团簇精确解一致的第 5 题。

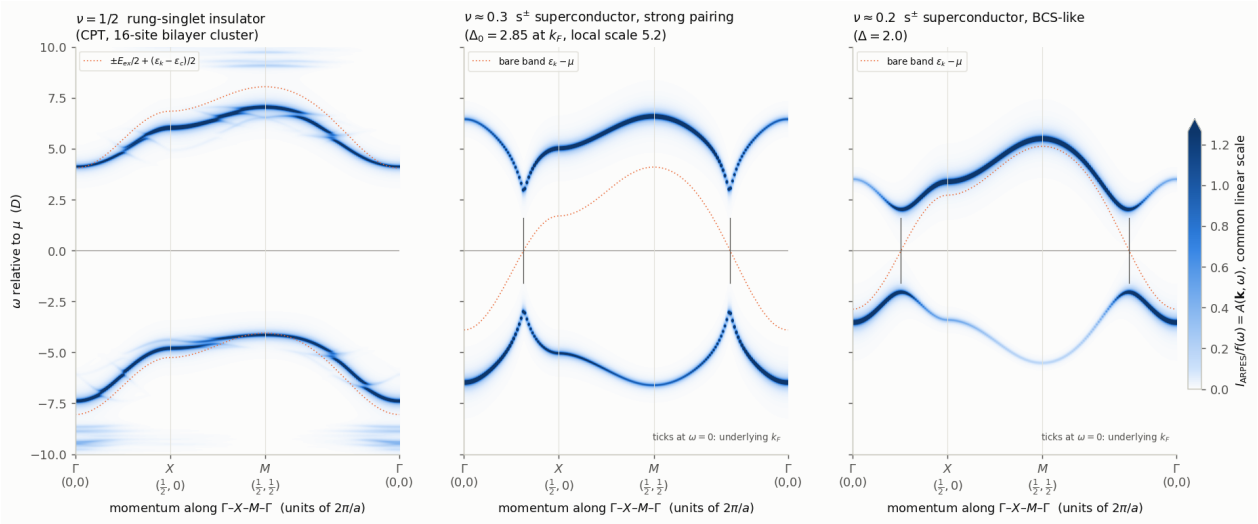


图 3: Opus run_01 图 4：三个填充的 ARPES。$\nu = 1/2$ 用 CPT，带宽约 3、卫星在 ± 9；$\nu \approx 0.3$ 用两能标 Bogoliubov；$\nu \approx 0.2$ 用 BCS。

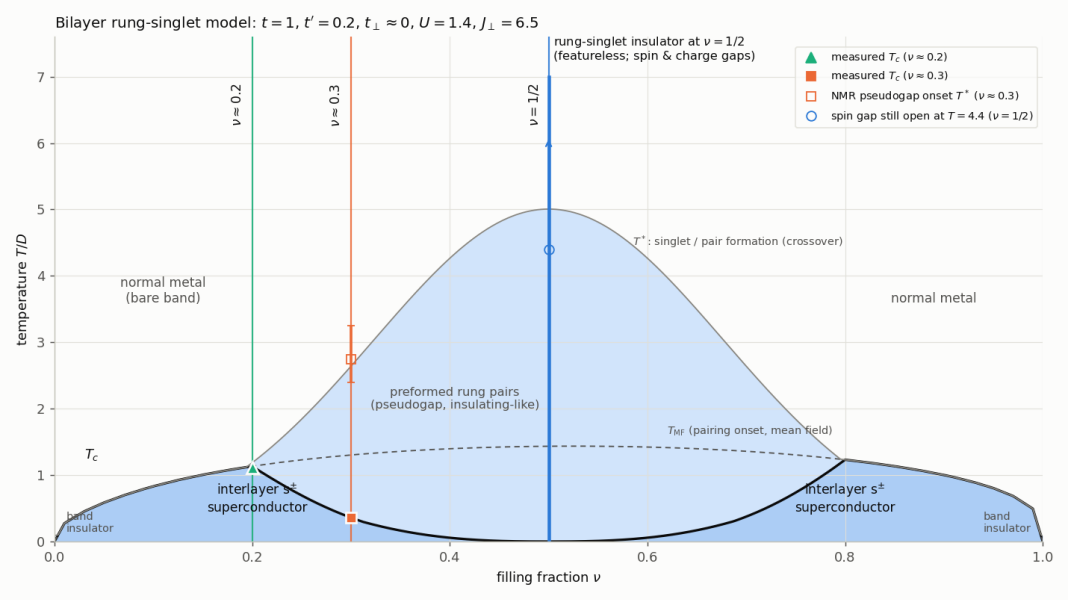


图 4: Opus `run_01` 图 3：相图。形状正确，$T_c(\nu)$ 为插值。

逐题评分。

- 第 1 题 19/20：模型、每一项、对称性、LSM 链、系数和不确定度全有；扣 1 分是 $J_\perp$ 被 $T_c = T_{\mathrm{MF}}$ 拉低、$U = 1.4$ 偏离 0（在其误差内）。
- 第 2 题 17/20：三块晶体的相序全对；扣分是 $T_c(\nu)$ 插值、接受 $T_c(0.2) = T_{\mathrm{MF}}$ 而把二维刚度矛盾推给层间耦合、T^* 曲线标注为示意。
- 第 3 题 18/20：§5 的表逐条对应，机制全对（三重子、holon/doublon 热激发、预形成对、Hebel–Slichter）；扣分是自旋能隙 4.7 对 5.5，以及 $\nu \approx 0.3$ 电阻率上翘只给了定性说法。
- 第 4 题 18/20：$\nu = 1/2$ 用 CPT 算出（且正确），$\nu \approx 0.2$ BCS 对；$\nu \approx 0.3$ 的两能标形式是数据反推。
- 第 5 题 19/20：方法（KK、和规则 0.9988、与直接 G 对比）、团簇外推 0.914→0.871→0.855、$t' = 0$ 对照、参数敏感性、零点带、与 ν 比较的原因，全部给出。

总评。　这是唯一一份把题目当成一个可以算出来的物理问题、并且真的算了的答卷（API 时间 2.4 小时，183 次 Bash，16 格点 ED 的 Hilbert 维数 1.66×10^8，费用是其他答卷的 4–6 倍）。它没有用“SMG”这个词，但物理内容就是 SMG：rung 单态、无破缺、LSM 允许、掺杂后的对 Mott 绝缘体。它的两处“错”——$J_\perp$ 偏低和 $T_c(0.2)$——都是题目旧版数据的错，而它在 §9 的“Limitations”里把两处都列了出来。

2.2　Claude Opus 5.5，`run_03`（83 分）

模型与结论。　双层 t–t'–$J_\perp$：$t = 1.000 \pm 0.005$, $t' = 0.194 \pm 0.003$, $J_\perp = 7.99 \pm 0.01\,(\mathrm{stat}) \pm 0.3\,(\mathrm{syst})$, $U = 0.04 \pm 0.01\,(+0.6\,\mathrm{syst})$, $|t_\perp| < 0.1$, $|J_\parallel| < 0.1$。半填充态“featureless rung-singlet insulator, also called a symmetric-mass-generation (SMG) insulator”。第 5 题：零点在带中心等高线 $\varepsilon_k = -4t'$ 上，Γ 侧 0.315 ± 0.002。

推理链与证据。 这份答卷是解析路线, 参数几乎全部命中 ($J_\perp = 8$、$U = 0$、$t' = 0.195$)。它的链条在 §1.1 写得很清楚：(1) 图 (d) 是裸带；(2) LSM："By the Lieb–Schultz–Mattis–Oshikawa–Hastings theorem, a gapped, symmetric and non-degenerate state with an odd number of electrons per unit cell must be topologically ordered. ... the observed spin gap (≈ 5.5) is far above any superexchange scale available from $t = 1$ ... The natural resolution is that the primitive cell contains two equivalent TM sites." (3) 图 (a)："A fit of $E_\pm = \pm\Phi + s(\epsilon_{\mathbf{k}} - \epsilon_c)$ gives $\Phi = 6.011 \pm 0.002$; slope $s = 0.497 \pm 0.001$, i.e. exactly $1/2$"，并给出物理解释"The amplitude is $t \times (1/\sqrt{2})^2 = t/2$"和"$\Phi = 3J_\perp/4 + U/2$"；(4) 图 (c) 的 BCS 耦合 $V = 3J_\perp/4 = 5.992$，故 $J_\perp = 7.99$；(5) 用 2–3 rung 团簇算二维三重子带 5.43–8.74，排除 $(J_\perp, U) = (6, 3)$（给 4.32，"excluded by 8σ"）。第 (5) 步有一段很好的自我纠错："A two-rung cluster ignores the dispersion of the triplon on the lattice. It would give 5.57 for $(6, 3)$ and 7.35 for $(8, 0)$, the opposite conclusion. ... This is the step on which the choice between the two parameter sets rests." Astra `run_01` 正是在这一步用孤立 rung 得到了错误的 $(U, J) = (3.7, 5.5)$。

它还在 §7 预言了高阶修正："the hole hopping falls from 0.50 to 0.38 (bands ∼3.0 wide instead of 4.0); the band centre falls from 6.0 to 5.7; the gap edge moves slightly, from 4.0 to 4.2"——与 10-31 的新图 (a)（带宽 2.7/3.0、斜率 0.33/0.39、内边 4.3）一致。它把这些写进了 U 的系统误差 ($+0.6$)，处理得当。

图。 图 5 的 (a) 面板同时画了 SMG 两极形式、Hubbard-I 形式和 BCS 镜像形式，SSE 分别为 0.32、1.89、16.8，是对"平移还是镜像"最直观的展示。图 6 的第 5 题：$\mathrm{Re}\, G < 0$ 在 Γ 周围，零点曲线几乎与 $\nu = 0.3$ 的裸费米面重合，份额 0.315。这与团簇精确解的符号相反。原因在它自己的公式里：$\mathrm{Re}\, G(\mathbf{k}, 0) \propto (\epsilon_{\mathbf{k}} - \epsilon_c)(1 - 2\alpha\Phi)/(\Phi^2 - d_{\mathbf{k}}^2)$——只要两极关于 ϵ_c 对称、残差为 $\frac{1}{2}[1 \pm \alpha(\epsilon - \epsilon_c)]$，零点就被钉在 $\epsilon = \epsilon_c$ 上，与 α 无关；而真实谱的两条带宽度不同（2.7 对 3.0）、残差的 k 依赖并不关于 ϵ_c 反对称，零点带因此反向色散，$\omega = 0$ 的零点轮廓跑到 $\epsilon \approx 1.9$。领头阶形式本身排除了这种可能。它在 §5 末尾指出"(If $t < 0$, the zeros would encircle M instead, and the side containing (0,0) would be $1 - 0.315 = 0.685$.)"，这是 rubric 要求的 (π, π) 歧义，只有四份答卷提到。相图（图 7）的问题：BCS 区与预形成对区的边界 $\nu^* \approx 0.24$ 由输运能隙外推到零的位置定，T_c 在那里"steep by construction"地从 1.1 掉到 0.4，这是人为的；$\nu < 0.24$ 处 $T_c = T_{\mathrm{MF}}$ 忽略了二维相位涨落（它在 §7 承认"Strictly 2D phase fluctuations would lower it"）。

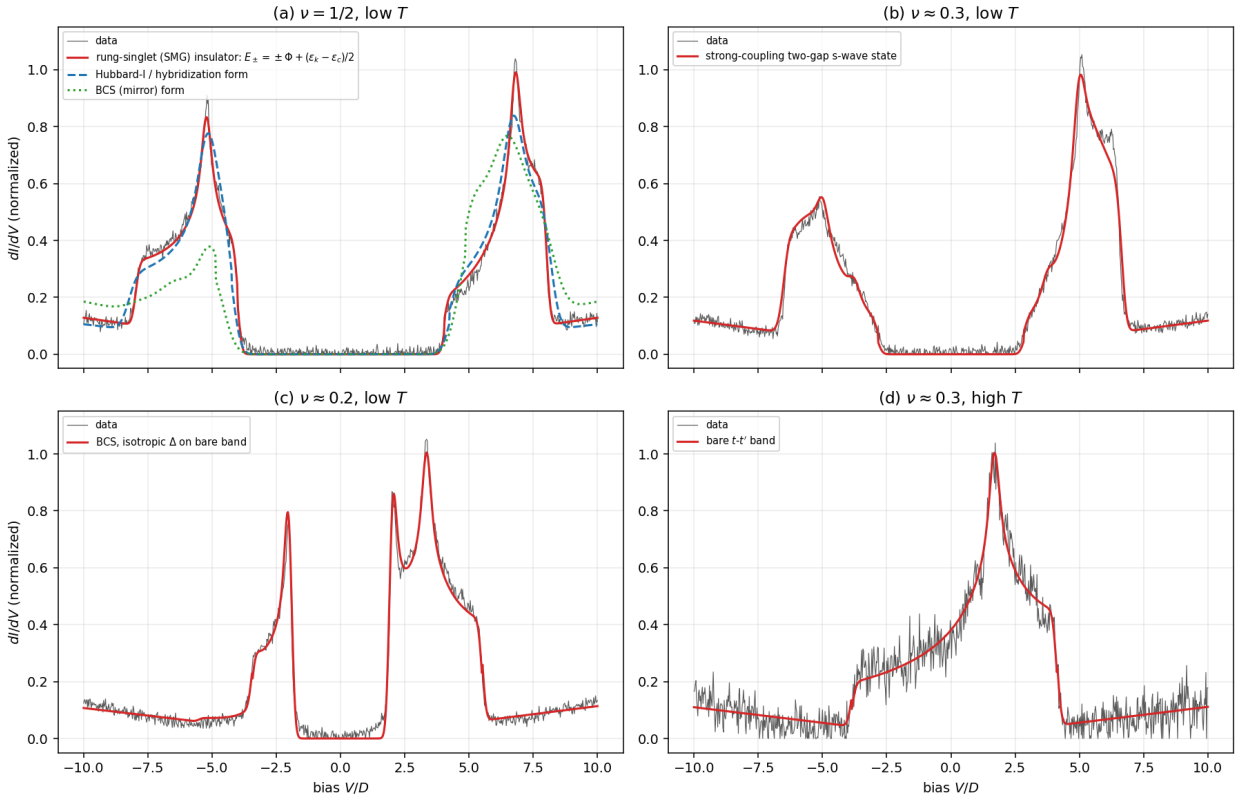


图 5: Opus `run_03` 图 1。(a) 三种形式的比较：SMG 两极（红）、Hubbard-I（蓝虚）、BCS 镜像（绿点）。(b) 两能隙 s 波唯象式。

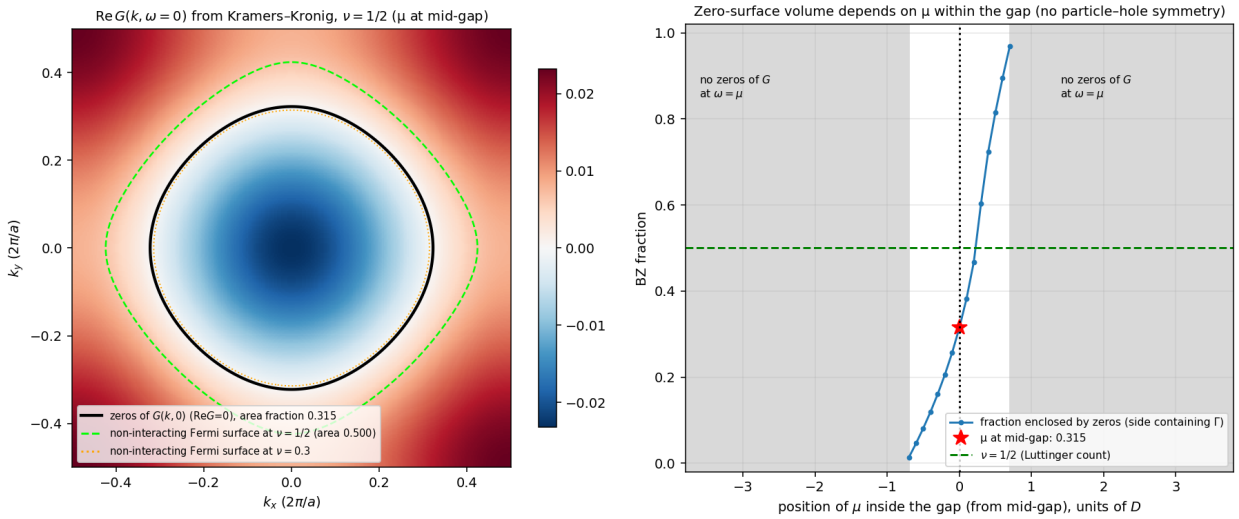


图 6: Opus `run_03` 图 5：零点曲线在带中心等高线上，Γ 侧 $\mathrm{Re}\,G < 0$，份额 0.315；右图份额随 μ 位置从 0 到 1。符号与团簇精确解相反，见正文。

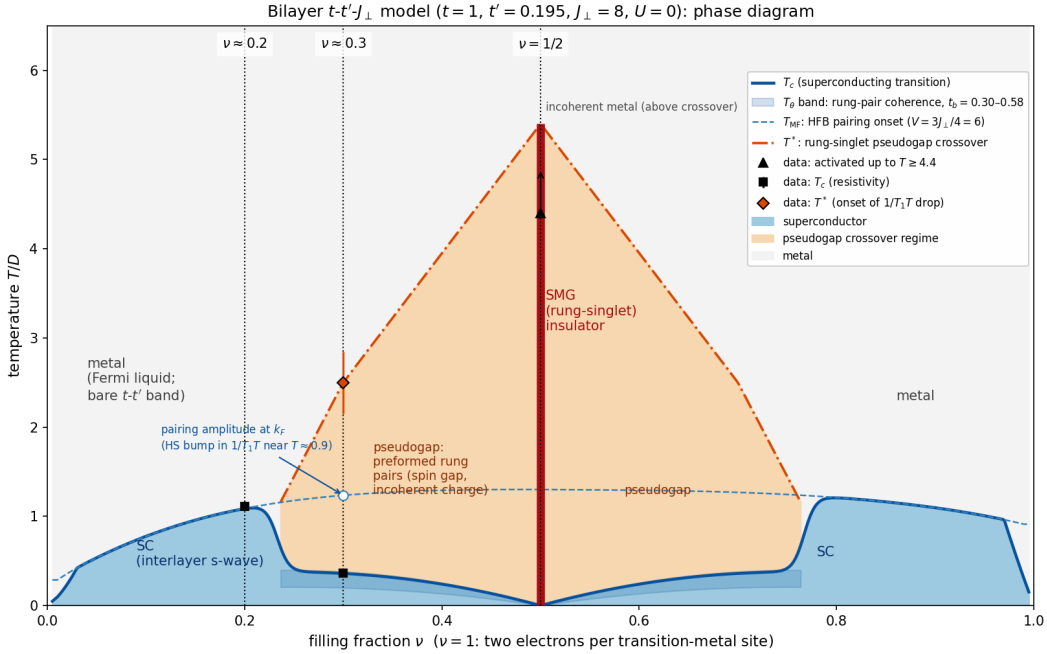


图 7: Opus `run_03` 图 3：相图。$\nu^* \approx 0.24$ 处 T_c 的陡降是构造出来的。

逐题评分。

- 第 1 题 18/20：模型、LSM、系数全对且不确定度区分了统计/系统；扣分是 $J_{\parallel}$、$t_\perp$ 的上界只是声明，以及把 $T_c(0.2) = T_{\mathrm{MF}}$ 当成 $J_\perp$ 的“check”。
- 第 2 题 16/20：相序对；T_θ 的硬核玻色子 KT 估计（0.20–0.38）是一个真正的计算，但 BCS/BEC 边界人为陡降、$\nu > 1/2$ 侧镜像、$T_c = T_{\mathrm{MF}}$ 不处理二维。
- 第 3 题 17/20：机制全对；$\nu \approx 0.2$ 的 Hebel–Slichter 峰高需要“transferred hyperfine coupling between the two TM sites of a rung”是为旧数据打的补丁；$\nu \approx 0.3$ 电阻率激活 0.90 归因于对–对排斥 $2V_b \approx 0.85$ 是猜测。
- 第 4 题 16/20：$\nu = 1/2$ 停在领头阶（它自己知道带宽应为 3.0）；$\nu \approx 0.3$ 唯象；$\nu \approx 0.2$ 对。
- 第 5 题 16/20：方法、扫描、(π, π) 歧义、与 ν 的比较都有；数值 0.315 与其谱自洽，但谱是领头阶的，符号与精确解相反。

总评。 参数最准、物理标签最准（“SMG”）的一份，代价是计算最轻（2–4 rung 团簇）。它和 `run_01` 的差别正好说明了领头阶强耦合与真实数值的差别出在哪里：带宽和零点的符号。

2.3 Claude Opus 5.5，`run_02`（57 分）

模型与结论。 单带吸引 Hubbard：$t = 1.00, t' = +0.197, U = -12.0 \pm 0.5$ at $\nu = 1/2$，“$U_{\mathrm{eff}} \approx -8 \pm 1.5$ at $\nu \approx 0.3$ and -6.0 ± 0.2 at $\nu \approx 0.2$”。半填充态是“insulating, spin-gapped liquid of preformed local (on-site) singlet pairs with no long-range order”，并预言“t' ... eventually selects s-wave superconductivity below $T \approx 0.08\,D$”。第 5 题：Γ 周围小圈，0.035。

推理链与证据。　这份答卷的数据分析质量与 `run_01` 相当（§1 的表很干净），差别在选模型那一步。它把 LSM 写出来了，但只对单电子态："Band insulator: Impossible with one electron per primitive cell and no broken symmetry (Lieb–Schultz–Mattis / Oshikawa–Hastings)"，然后对 Cooper 对再写一次："The Lieb–Schultz–Mattis constraint for charge-2e pairs at half filling (one pair per two sites) forbids a featureless $T = 0$ ground state; the theory satisfies it through the predicted superconductivity at $T \to 0$."——也就是说它看到了约束，然后用"预言测量窗口以下有序"来满足约束，而不是改模型。新版题目加的那句"电阻一直升到 $0.05D$、无新衍射峰"直接针对这条路。

它的诚实之处值得记录。§2.4 末尾"Quantitative limitations, stated plainly"列了四条：(1) 单一 $U = -12$ 的 ED 在所有填充给能隙 3.6–4.2（数据 1.96、2.65、3.97），"Reproducing the doped gaps needs the screened U_{eff} above, an ingredient beyond the minimal Hamiltonian"；(2) "In the clean model, pairs at $\nu = 1/2$ would conduct (pair hopping 0.17)"，需要无序钉扎；(3) 高温谱比静态 $U = -12$ 允许的更尖锐；(4) $T_c = 1.1$ 超出二维刚度上界。四条里前两条就是这个模型不成立的理由，它都写了，但没有据此换模型。还有一处内部不一致：NMR 激活 5.54 用原子极限的 $|U|/2 - 2t' = 5.6$ 解释，电阻率激活 3.72 用带边 $E_g/2 = 3.97$ 解释，而在吸引 U 模型里这两个过程激发的是同一种准粒子。

图。　图 8：零点是 Γ 周围半径约 0.1 的小圈（0.035），Re G 几乎处处为正；右图显示份额随权重标度 U_w 从 0（$U_w \le 13.6$，无零点）到 0.314（等权重）。这张图实际上证明了第 5 题对残差的敏感性——同一份数据，权重参数在拟合误差范围内变一点，答案在 0 和 0.31 之间移动。相图（图 9）形状与 `run_01` 相似，但在 $\nu = 1/2$ 处标了 "$T_{KT}(1/2) \approx 0.08$ (predicted)"。

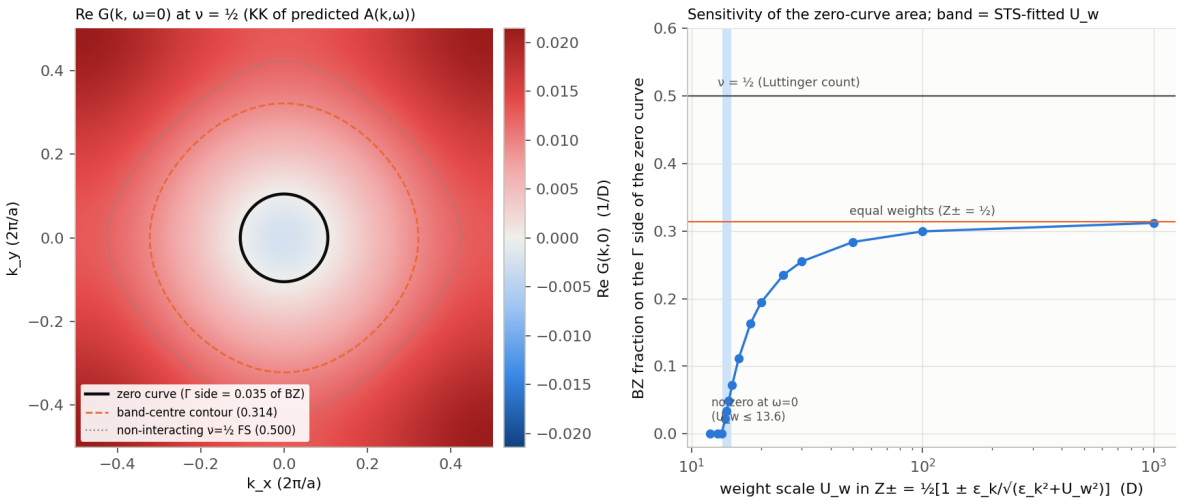


图 8: Opus `run_02` 图 6：零点小圈（0.035）与份额对权重标度的敏感性。

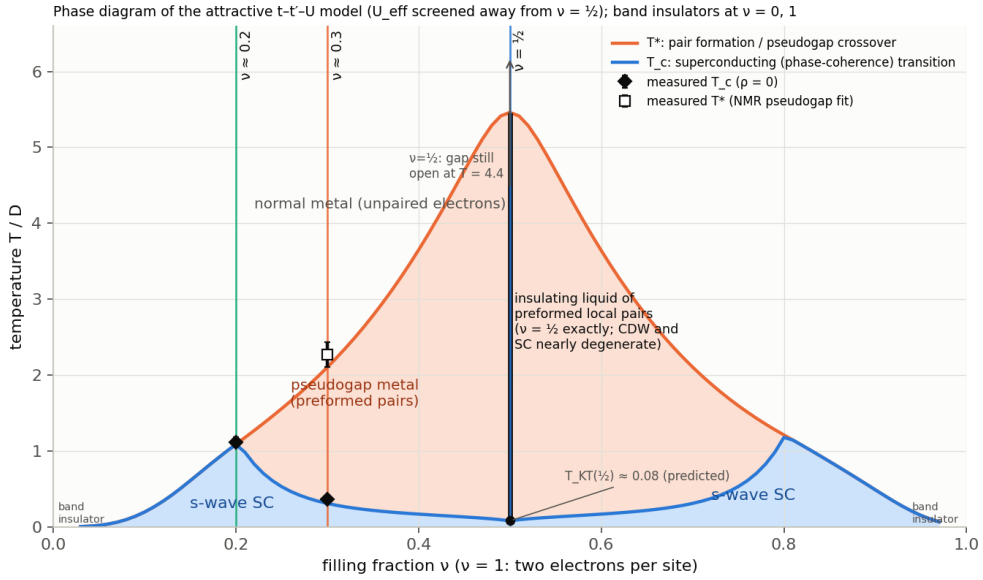


图 9: Opus `run_02` 图 4：吸引 Hubbard 模型的相图，$\nu = 1/2$ 处预言 $T_{KT} \approx 0.08$ 的超导。

逐题评分。

- 第 1 题 7/20：动力学项和不确定度对；模型错，而且 $U_{\text{eff}}(\nu)$ 使它不是“一个”哈密顿量；LSM 写了但用错。
- 第 2 题 10/20：掺杂两块的相序对；$\nu = 1/2$ 预言低温超导/CDW，与题意相反；相图的 T_c 用两个常数校准。
- 第 3 题 11/20：掺杂态的解释大体成立；半填充的 NMR/电阻率解释内部不一致（见上）；图 (d) 无卫星靠“在窗口外”解释。
- 第 4 题 13/20：$\nu = 1/2$ 的两条平移带、$\nu \approx 0.2$ 的 BCS 对；$\nu \approx 0.3$ 的“broad, weak quasiparticle”是数据反推。
- 第 5 题 16/20：KK 方法、bootstrap、与 ν 比较、$t' = 0$ 对照都有；数值 0.035 与其谱自洽；符号与精确解相反。

总评。 与 `run_01` 同一个模型、同一组工具，差别只在是否愿意把 LSM 的结论当真。它的四条“limitations”说明它看见了问题，但把“换成双层”这一步留给了读者。

2.4 Claude Fable 5.1，`run_01`（57 分）

模型与结论。 单层吸引 Hubbard，$U = -12$，$|U_{\text{eff}}| = 12.0/8.5/6.0$（“a running coupling”）。半填充态是“pair (bipolaronic) insulator”。第 5 题：CPT（2×2、2×4、3×4 团簇）给 0.46 ± 0.02。

推理链与证据。 它用 ED 判定 U 的符号：“for $U = +12\,D$ the spin gap of the same clusters is $0.15\,D$, for $U = -12\,D$ it equals the charge gap”（§1 表，2×2 到 3×4 团簇）。这个判断本身是对的——在单层模型里，只有吸引 U 能给 5.5 的自旋能隙——错在前提。§0 的表把“Diffraction, NMR

line”一行写成“one TM site per cell at all T … given”，这是对题面的误读：题目给的是面内周期等于金属–金属距离，没有说原胞里有几层。十一份答卷里凡选单层的，都在这一步把“面内一个位点”读成了“原胞一个位点”。随后它的物理推理在单层框架内是自洽的：“A charge gap and a spin gap of the same magnitude, without broken symmetry, identify the half-filled state as a local-pair … insulator”，并为 $\nu = 1/2$ 做了可证伪的预言：“below $T \sim 0.1$–$0.2\,D$ the half-filled crystal should either develop weak superlattice peaks at $(1/2, 1/2)$ or become superconducting”——新版题目的 $0.05D$ 句子把这个预言否定了。

$U_{\mathrm{eff}}(\nu)$ 的处理是全篇最勉强的地方：“This is the expected behaviour of a lattice-mediated (bipolaronic, valence-skipping-type) negative-U centre whose binding is screened by itinerant carriers”——三块晶体用三个耦合常数，每个单独拟合，然后用一条直线 $|U_{\mathrm{eff}}| \simeq 6.0 + 20(\nu - 0.2)$ 串起来。题目要求“一个理论”；这不是。

图。　图 10 是它的 CPT 零点图：吸引模型（上排）的零点曲线贴近裸费米面，份额 0.457–0.467；排斥模型（下排左三）0.52–0.54；两极形式（下排右二）无零点或 0.136。CPT 计算本身做得扎实（3×4 团簇 853 776 态，KK 与直接 G 一致到 2×10^{-5}），Re G 的量级（± 0.08）比双层模型（± 0.02）大四倍，这是因为吸引 U 模型的零点带正好穿过中隙附近。相图（图 11）用 $T^{*} = 0.65\Delta_{pg}$ 和 $T_{\theta} \propto (1 - 2\nu)^{3}$ 插值，并画出了单层 KT 上界 $(\pi/2)\rho_{s}^{\mathrm{MF}} = 0.13$–$0.2$——它看到了 $T_{c}(0.2) = 1.1$ 超出上界，结论是“interlayer coupling makes the transition three-dimensional there”。

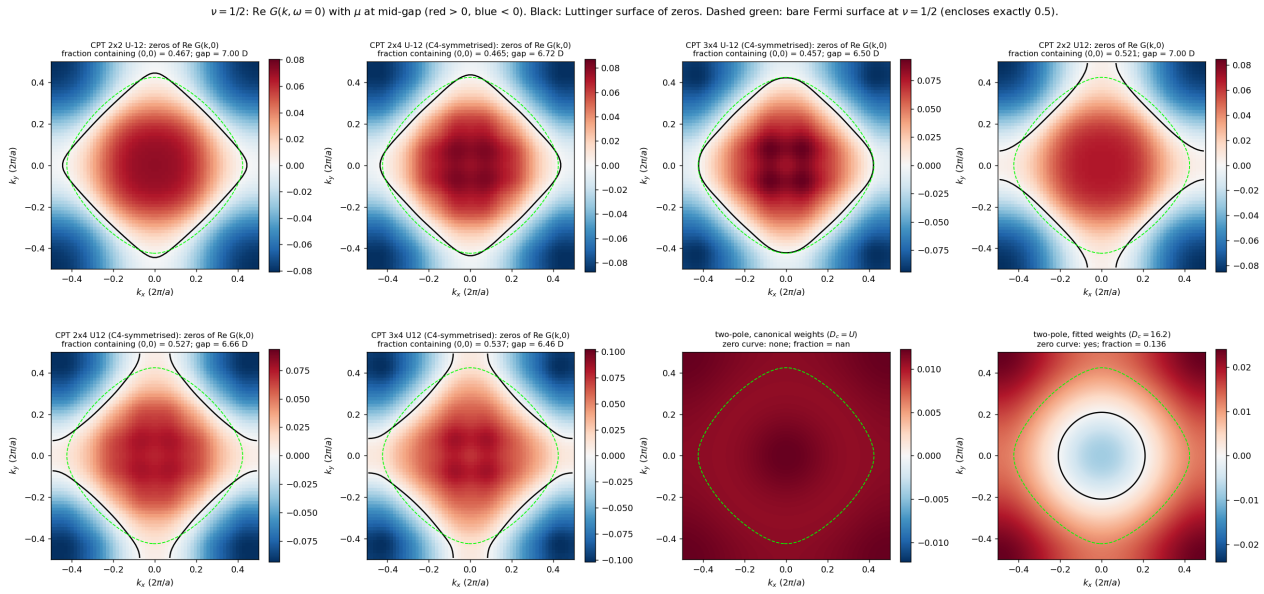


图 10: Fable `run_01` 的 CPT 零点图。吸引 U（上排）0.46，排斥 U（下排左）0.53，两极形式无零点或 0.136。

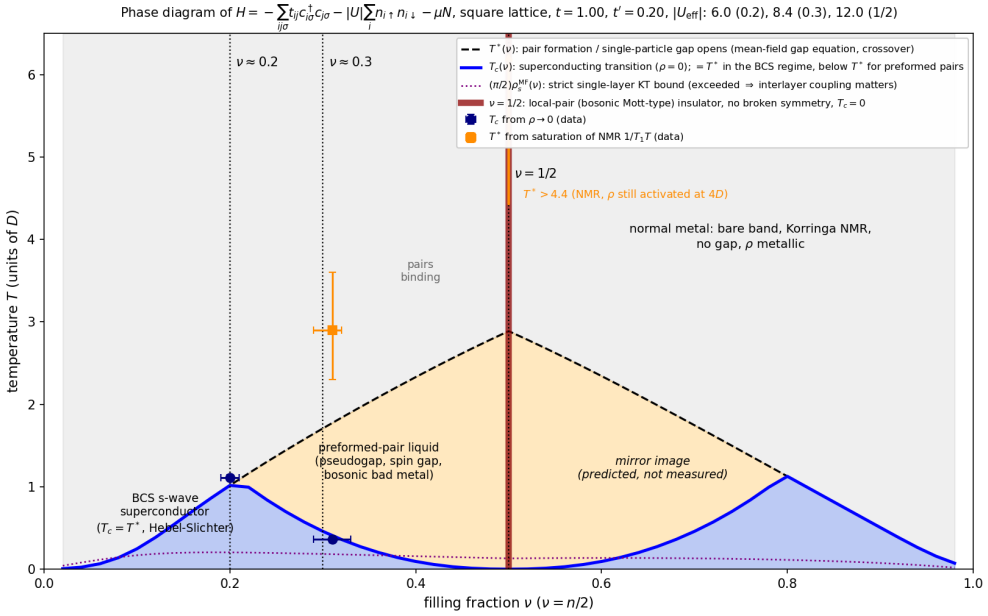


图 11: Fable `run_01` 的相图，含单层 KT 上界（紫点线）。

逐题评分。

- 第 1 题 7/20：动力学对；单层误读题面；$U_{\rm eff}(\nu)$ 非单一理论；无 LSM。
- 第 2 题 10/20：掺杂相序对；$\nu = 1/2$ 预言低温有序；T_c 插值。
- 第 3 题 11/20：掺杂态解释合理；半填充 NMR 用 $|U|/2$、电阻率用 $E_g/2$ 的同一问题；图 (d) 的卫星问题未查。
- 第 4 题 13/20：$\nu = 1/2$ 两带对；$\nu \approx 0.3$ 的“ghost Fermi surface, no back-bending”与生成谱的“无尖锐 back-bending”部分吻合；$\nu \approx 0.2$ 对。
- 第 5 题 16/20：CPT 做得好，团簇序列、KK 核对、U 两种符号的对照都有；数值 0.46 与其模型自洽。

总评。 在单层框架里它做到了能做的一切，包括最重的数值（3×4 团簇 CPT）。它和 Opus `run_01` 的区别在于：Opus 做完单层 ED 发现不对就换模型，Fable 做完发现不对就加一个随掺杂变的 $U_{\rm eff}$。

2.5 Claude Fable 5.1，`run_02`（51 分）

模型与结论。 单层排斥 Hubbard $U = 12.0$ 加一个独立的 s 波 Cooper 道吸引 $V = 6.0$。半填充态是“paramagnetic Mott insulator”。第 5 题：Γ 周围闭合曲线，0.14 ± 0.04。

推理链与证据。 它的 STS 分析是对的（“two bands ... each a copy of this band compressed by one half”，Hubbard-I 权重 $Z_\pm = \frac{1}{2} \pm \varepsilon_k/2U$）。问题在自旋部分。半填充排斥 Hubbard 的自旋能标是 $J = 4t^2/U = 0.33$，二维正方格子基态是 Néel 序（会使 NMR 线分裂或移动、并在 $(1/2, 1/2)$ 出衍射峰），它选择称之为“quantum paramagnet”而不给理由。为了解释 5.6 的激活，它构造了

一个机制：“the transferred hyperfine form factor $(A+2B\sum\cos q_i)^2$ of a perovskite B-site nucleus vanishes at $q=0$ ... intraband relaxation with momentum transfer (π,π) requires $E(k)=E(k+Q)$, which happens only on the antiferromagnetic zone boundary where the lower Hubbard band lies 5.2–5.6 below μ”。这是把单粒子带间激发当成自旋弛豫的来源；而 Mott 绝缘体的低能自旋激发是能标 J 的磁振子/自旋子，与单粒子能隙无关，$1/T_1$ 在 $T\sim J$ 以上应接近常数。Sol `run_01` 的 10 自旋团簇计算（见 2.10 节）正好定量地否定了这条路：排斥 Hubbard 的自旋响应比数据大五个量级。

两个相互作用的问题它自己承认：“The last term is the s-wave (k-independent) projection of a retarded attraction between carriers (phonon/bipolaron-like; its microscopic origin is not resolvable from these data). It is distinct from the instantaneous on-site U and acts only on the doped carriers' pairing channel.”一个排斥 $U=12$ 和一个吸引 $V=6$ 同时作用在同一个轨道上，微观上没有来源，题目要求“最可信”的理论，这不是。

图。 图 12：$\nu\approx0.3$ 画成两条同向色散、权重互换的 Hubbard 型分支，“no back-bending”。这与它自己说的“$\nu\approx0.3$ 是预形成对的超导体、$T_c=0.36$ 以下相干”矛盾：一个有凝聚的配对态，无论耦合强弱，其 Bogoliubov 谱都是关于 μ 镜像的，差别只在镜像分支的权重。同向分支是 Mott 型（电荷）能隙的特征，不是配对能隙的特征。$\nu=1/2$ 和 $\nu\approx0.2$ 两幅对。

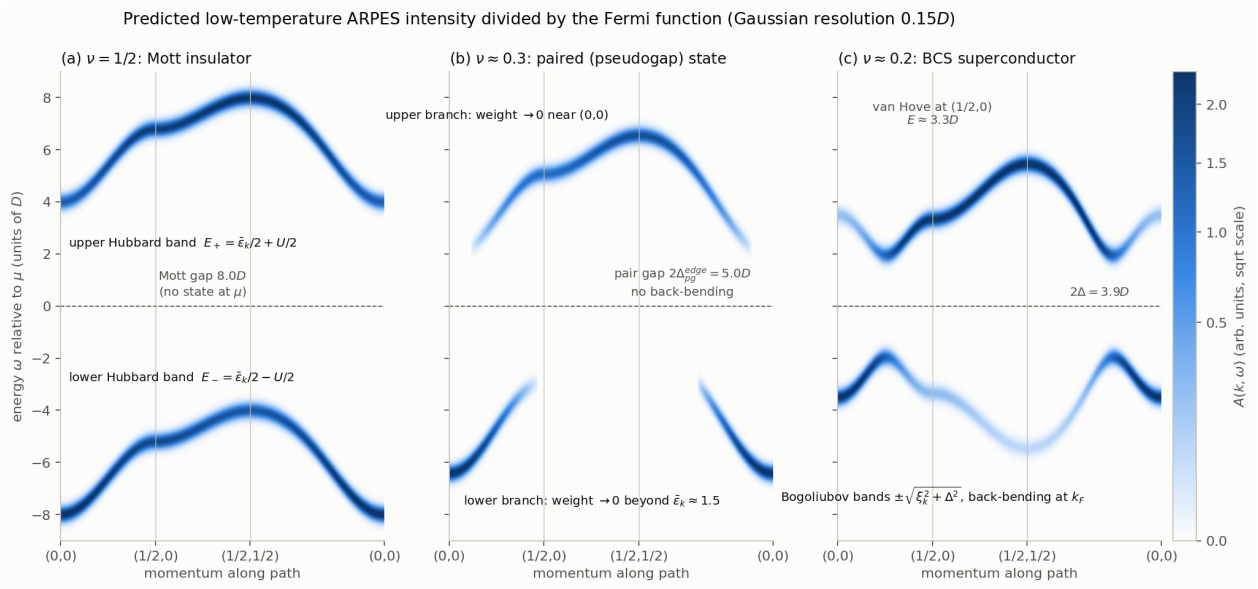


图 12: Fable `run_02` 的 ARPES：中图 $\nu\approx0.3$ 画成同向色散的 Hubbard 型分支，与超导态的镜像谱不符。

逐题评分。

- 第 1 题 5/20：动力学对；排斥 U 与 5.5 自旋能隙不相容；两个相互作用；无 LSM；单层误读。
- 第 2 题 9/20：掺杂相序对；$\nu=1/2$ 的“paramagnetic Mott insulator at all T”在排斥 Hubbard 里不成立（应有 Néel 或至少 J 量级的自旋涨落）。
- 第 3 题 9/20：(π,π) 形状因子机制不成立；其余解释与 `run_01` 类似。
- 第 4 题 13/20：$\nu\approx0.3$ 画错（同向分支）。

- 第 5 题 15/20：KK 方法、零点带 $\omega_z(k) = 0.11\bar{\varepsilon}_k + 0.21$、Hubbard-I 平坦零点带无零点的讨论都对，0.14 与其谱自洽。

2.6　Claude Fable 5.1，`run_03`（49 分）

模型与结论。　与 `run_02` 同类：单层 t–t'–U（$U = 12.02 \pm 0.05$）加 Cooper 道 $g = 6.1 \pm 0.2$。第 5 题：“the Kramers–Kronig Green’s function at $\omega = 0$ does not change sign anywhere in the zone”。

推理链与证据。　STS 分析细致：它检验并排除了 Hubbard-I 全重求和和 Hatsugai–Kohmoto 模型（“excluded by the unequal edge heights of the two bands”），残差 $w_{\mp} = \frac{1}{2}(1 \mp \alpha\varepsilon_k)$，$\alpha = (1.02 \pm 0.07)/U$。对自旋能隙它比 `run_02` 诚实：“The local-bubble model with the fitted bands gives 4.3 …; the data are steeper by $\approx 1\,D$, which the purely local formula does not capture (a relaxation weighted toward the antiferromagnetic wavevector … would)”，并在 §6 列为局限。$\nu \approx 0.3$ 它用“Mott 压缩的 Bogoliubov 镜像带”（$E_k = c + a\varepsilon_k + b\varepsilon_k^2$，$a = 0.56$），这比 `run_02` 的同向分支更合理（有镜像结构和相干因子），但明说是唯象的。

第 5 题它得到的结论是“Re $G(k, 0)$ is positive at every k … the zeros … fill the zone at $\omega = +0.39\,D$”，即领头阶 Hubbard-I 型平坦零点带（图 13）。它正确地说明了原因（“the self-energy pole … lies $2t'$ above the gap centre of the particle–hole-asymmetric band”）、给出了“如果自能极点色散 λ”时的份额曲线、并指出数据把 λ 限在 $\lesssim 0.05$。这是“没有曲线”这一档里写得最清楚的；题目 rubric 对此给部分分。

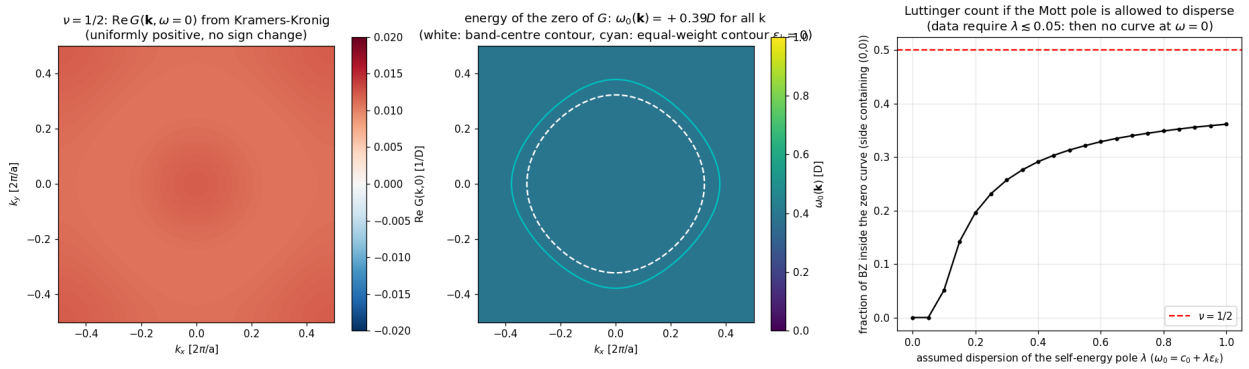


图 13: Fable `run_03` 的第 5 题：Re $G(k, 0)$ 处处为正，零点带平坦在 $+0.39D$；右图是假设自能极点色散时的份额。

逐题评分。　1 题 5/20（同 `run_02`）；2 题 9/20；3 题 9/20（NMR 的 $\nu = 1/2$ 解释自知不足；输运 $\nu \approx 0.3$ 高估 2–3 倍，自己写明）；4 题 12/20（$\nu \approx 0.3$ 唯象、$\nu = 1/2$ 领头阶）；5 题 14/20（无曲线但原因、扫描、$t' = 0$ 对照齐全）。

总评。　`run_02` 和 `run_03` 是同一个模型的两次独立实现，分数相近。Fable 三份答卷的共同模式是：数据分析精细、唯象形式丰富、但在“这个模型能不能给 5.5 的自旋能隙”这个判断上一次都没有停下来重新选模型。

2.7 GPT-6.1 Sol，`run_02`（47 分）

模型与结论。 不选微观模型。它给出的“Hamiltonian”是一个辅助轨道 f 与物理轨道 c 杂化的二次型“spectral Hamiltonian”，参数 t, t', s, V, r 全部由图 (a) 拟合（$s = 0.502$，$V = 6.003$，能隙 8.0019，95% 区间 $[7.981, 8.026]$），并明说：“This is not a validated microscopic Hamiltonian for the material. Interpreting f as an independent charged orbital would change the physical degrees of freedom and filling count.”第 5 题：0.0813，95% 区间 $[0.044, 0.108]$。

推理链与证据。 这份答卷的拟合是十一份里最精细的（bootstrap、协方差、raw-observable 似然、不缩小误差），而且它找到了题目的两处真实缺陷：

- 二维刚度：“the superfluid stiffness bound ... The upper bound $0.43598 \pm 0.00229D$ is below the observed lower transition bracket $1.075D$ at nominal $\nu = 0.2$. This rules out that entire conjunction of assumptions”（图 14，引 Hazra–Verma–Randeria）。它没有像 Anthropic 的答卷那样把矛盾推给三维耦合，而是把它当成模型–数据的矛盾列出。出题方随后把 $T_c(0.2)$ 改为 $0.40D$。
- (c) 的粒子数：“The unconstrained fit succeeds spectrally but gives a different filling under its number equation ... Calculated filling $\nu = 0.2564$ ... Imposing exactly $\nu = 0.2$ raises [the RMS] to 0.0602.”这是旧生成器用正常态 μ 画 BCS 谱留下的不自洽，后续版本把能隙方程和粒子数方程联立求解后消失。

它也指出“a Hubbard-dimer ... Matching the half-filled NMR activation as a triplet gap at fixed $U = 12D$ would require $t_\perp = 4.9288D$”，用来说明“从峰分裂推 U 再宣称自旋部分已解决是不合理的”——这个论证对单层排斥模型成立。但它随后写“A bilayer Hubbard model with interlayer singlets is one possible microscopic candidate because the layer count is unspecified”，到此为止。

图。 图 15：三张 ARPES 图里中间一张明确标为“rejected two-pole candidate”（六个拟设全部失败，RMS 0.046–0.065 对噪声 0.015），右图标“calculated filling 0.256”。它宁可展示失败也不画一张好看的插值，这是它的原则：“The missing momentum information cannot be repaired by drawing a visually plausible interpolation.”相图是“measured state map”，灰色区域“unresolved”。

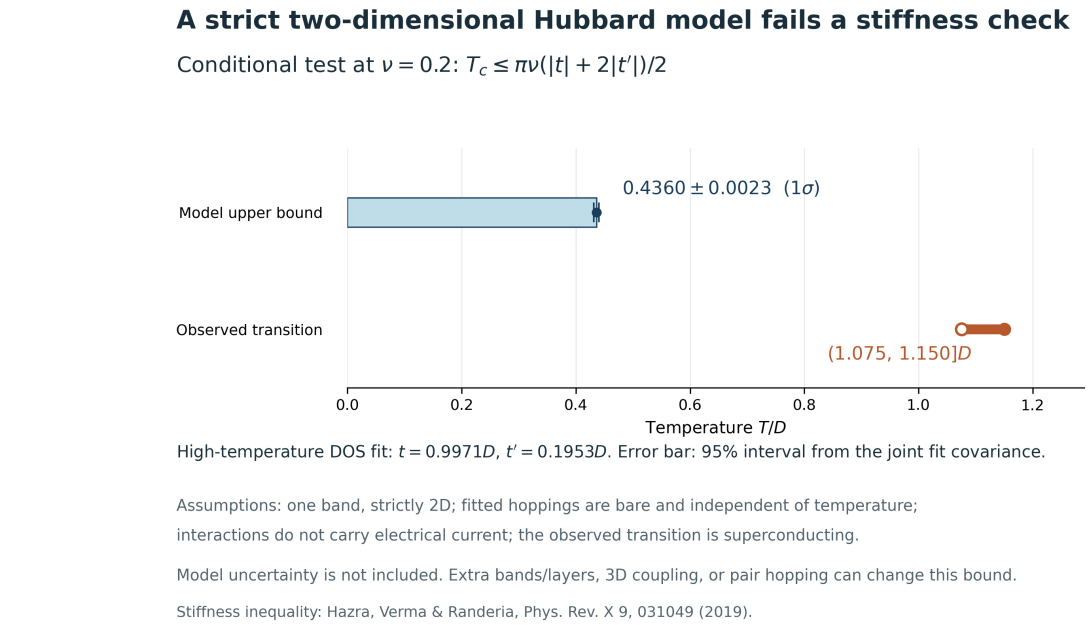


图 14: Sol `run_02` 图 8：二维刚度上界 0.436 对观测 $T_c \in (1.075, 1.150]$。这个矛盾是题目的错，已改。

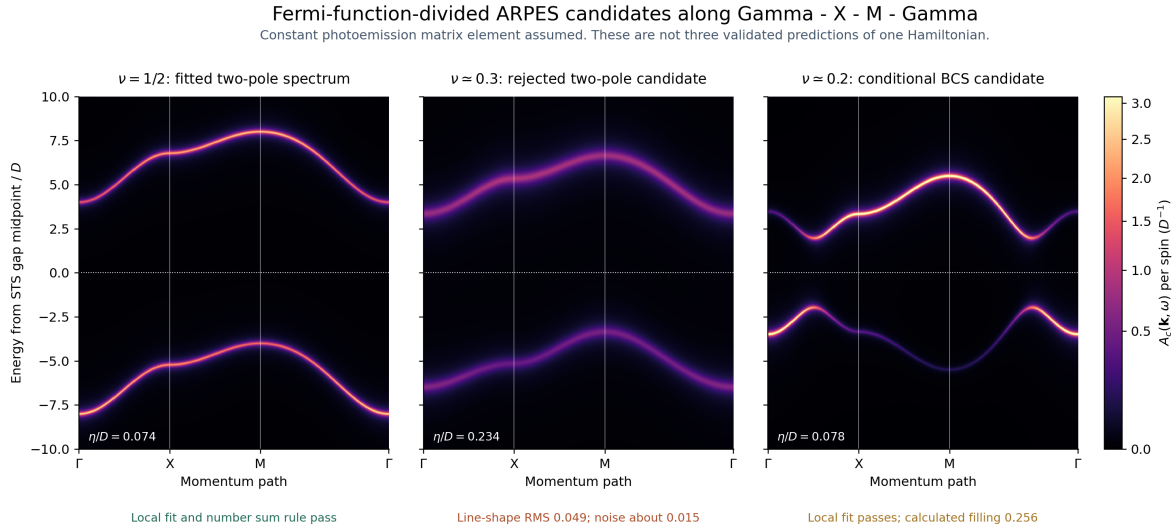


图 15: Sol `run_02` 图 9：中图是“rejected”候选，右图标注粒子数 0.256。

逐题评分。

- 第 1 题 9/20：动力学项及其不确定度做得最好；但没有微观模型，“spectral Hamiltonian”不是题目要的理论；提到双层而不采用。
- 第 2 题 5/20：只有测量约束图；但刚度上界的检验是实质性的物理内容，给分。
- 第 3 题 9/20：§14 的表把每组数据的“supported implication”和“model-dependent”分开，分析正确但不解释机制。
- 第 4 题 8/20：$\nu = 1/2$ 的两极谱对，$\nu \approx 0.2$ 的 BCS 对，$\nu \approx 0.3$ 明示失败。

- 第 5 题 16/20：KK、收敛、清洁 $\eta \to 0$ 极限、(π,π) 反例、λ 参数族反例（0.85/0.71/0.66）全有；数值 0.081 与其谱自洽。

总评。 如果题目问的是“数据能确定什么”，这是最好的一份；题目问的是“最可信的理论是什么”，它交了白卷。它对题目的两处纠错价值很高。

2.8 GPT-6 Astra，`run_01`（46 分）

模型与结论。 给出一个“trial Hamiltonian”——正是双层 t–t'–$t_\perp$–U–$J_\perp$——然后在系数表里写“$t_\perp$: Not identified. ... $U, J_\perp$: Not separately identified.”，“conditional starting values $J_\perp \simeq 5.53 \pm 0.15$ and $U \simeq 3.71 \pm 0.22$”。第 5 题：0.0754，Γ 侧 $\mathrm{Re}\, G < 0$。

推理链与证据。 它是唯一一份写出了双层哈密顿量并说明机制（“For sufficiently strong antiferromagnetic rung exchange, the half-filled reference state can be a product of vertical singlets ... Doping makes paired charge configurations mobile and can favor the interlayer singlet amplitude”）、还引用了出题人课题组文献的 OpenAI 答卷，但它拒绝把这当结论：“A bilayer is a possible model assumption, not a fact established by these inputs.”它对 LSM 的表述也是条件式的：“If instead there is one spin-1/2 per full primitive cell, a fully symmetric, fully gapped insulating state ... cannot be an ordinary unique singlet product state.”——它把两种情形并列，不做选择。

它的 $(U, J_\perp) = (3.7, 5.5)$ 来自把 NMR 激活等同于孤立 rung 的单重–三重能隙（$J_\perp$），忽略三重子在格子上的色散；Opus `run_03` 明确指出这一步会得出相反结论。它的两极拟合（$t_h = 0.4985$, $M = 6.003$，$b = 0.0647$）与 Sol `run_02` 几乎相同；零点份额 0.0754 的协方差传播、(π,π) 平移反例（0.9246）、以及“在 $10D$ 以外加未测谱重”的反例（0.045–0.110）在数学上都对。它还做了 (c) 的粒子数检验（0.25588），与 Sol 一致。

图。 图 16：中图 $\nu \approx 0.3$ 是“局域连续谱反例”——两条水平的无色散带，标题写明“not a claim that this crystal has flat bands”。作为“STS 不能确定动量分布”的数学说明它是对的，作为第 4 题的答案它什么都没说。右图 $\nu \approx 0.2$ 的 BCS 是对的。相图（`phase_constraints.png`）是三条竖线上的测量区间，其余留白。

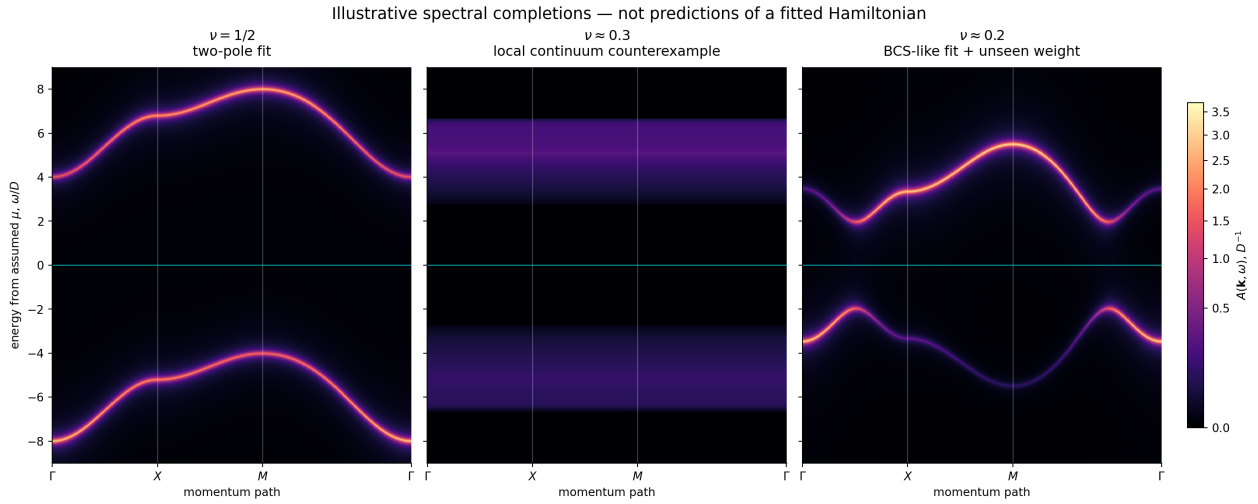


图 16: Astra `run_01` 的“illustrative spectral completions”。中图是故意构造的无色散反例。

逐题评分。 1 题 9/20（写了正确的模型和机制，不承诺，参数错）；2 题 4/20（约束图）；3 题 9/20（机制讨论正确但处处保留）；4 题 8/20；5 题 16/20（自洽数值 + 两类反例 + Rosch 引文）。

总评。 这份答卷离正确答案只差一个决定。它查到了文献、写出了模型、算出了两极谱，然后在每一段末尾加一句“this is not a deduction”。

2.9 GPT-6 Astra，`run_02` 与 `run_03`（各 32 分）

两份结构相同，合并评判。`run_02` 的“starting model”是单层 t–t'–U Hubbard；`run_03` 扩展为 t_1–t_2–U–J_1–J_2。两份都明说“I have not established that any particular member reproduces all the data.”两份都正确指出了单层排斥 Hubbard 的致命问题：“$J_1 \simeq 4t^2/U \simeq 0.33$ ... These are very different from the $5.54D$ activation scale in half-filled spin relaxation”（`run_02`），并把 LSM 写成条件句（“If one further assumes one spin-1/2 per primitive cell ... a featureless unique gapped state is obstructed”），然后给出“Possible resolutions include interlayer singlets, additional interactions or spin anisotropy, or a different correlated state. The supplied data do not select or parameterize them.”——“interlayer singlets”就在它的候选清单第一位。

两份的主要内容是不唯一性构造。`run_02` 的构造 (7)：用 STS 两支的累积分布函数 $Q_\pm$ 和任意排序函数 $e_b(\mathbf{k})$ 造出局域 DOS 完全相同、动量分布任意的谱；`run_03` 的构造 $A_{\nu,\lambda} = [\nu + \lambda h(\mathbf{k})]p_- + [1 - \nu - \lambda h(\mathbf{k})]p_+$，并给出同一局域谱、同一填充、同一中隙 μ 下零点份额为 0.50、0.60、0.80 的三个例子。这些构造数学上无懈可击，并且 `run_02` 有一个有价值的观察：“Hubbard-I cannot be used to claim the closed zero curve stipulated in the question. A momentum-dependent self-energy or an appropriately justified larger internal structure is required.”——这与 Fable `run_03` 的发现一致，也是题目 rubric 里“Hubbard-I 谱没有闭合零点曲线”那一条。

图 17（`run_02`）显示的问题在于：它的“completion”在 $\nu \approx 0.2$ 画出的是一个 $3D$ 宽的硬能隙、无 back-bending 的谱，这在数学上满足局域 DOS，但与它自己承认的“coherent Bogoliubov features would be the more natural expectation”矛盾——反例是为了说明“数据不能排除”，不是为了说明“物理上可能”。两份答卷都没有相图、没有预测、没有参数。

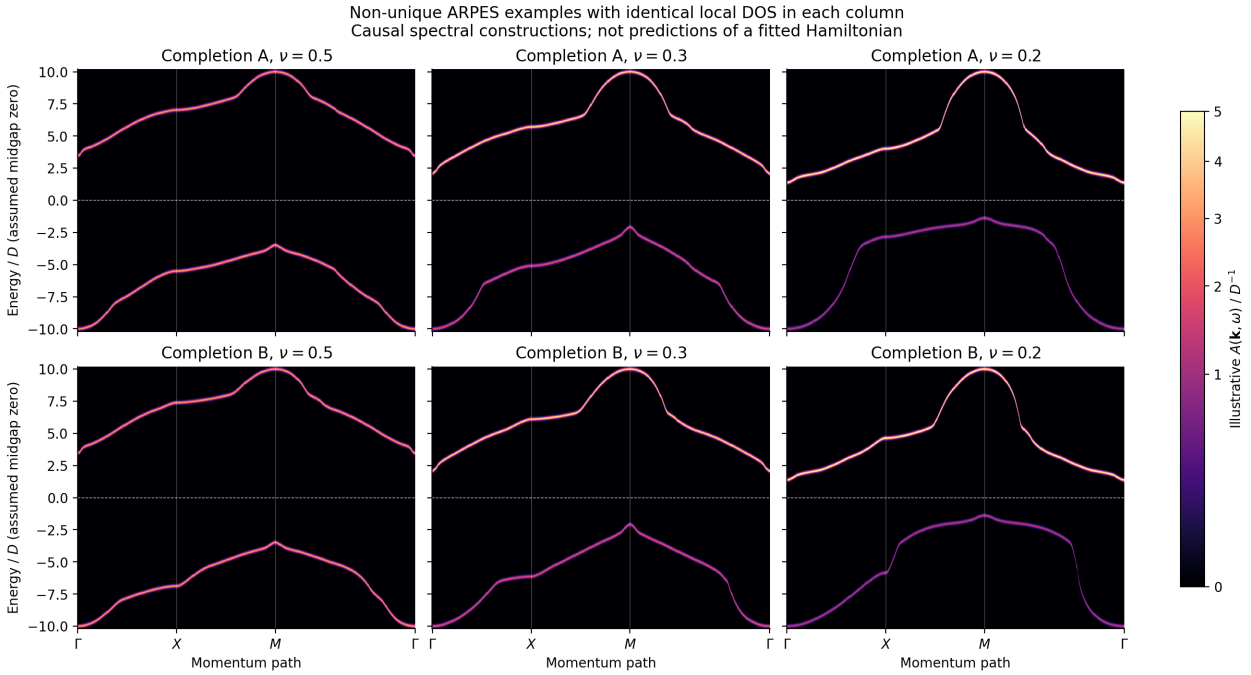


图 17: Astra `run_02` 的不唯一性构造：每一列两行的局域 DOS 完全相同。右列 $\nu \approx 0.2$ 的谱没有 Bogoliubov 结构。

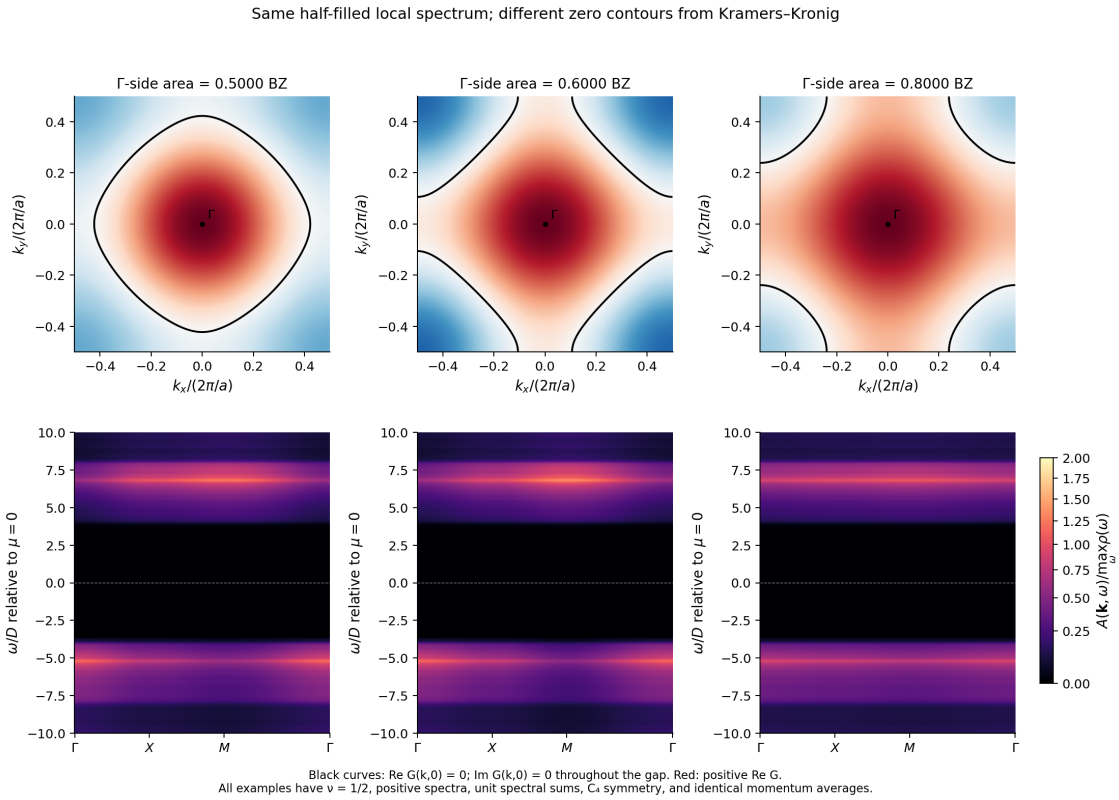


图 18: Astra `run_03`：同一局域谱、同一填充下零点份额 0.50、0.60、0.80 的三个构造。

逐题评分（两份相同）。 1 题 4/20（起点模型 + 系数“不可识别”）；2 题 3/20（约束图）；3 题 8/20（对每组数据的“supported implication”分析正确、无机制）；4 题 5/20（反例）；5 题 12/20（KK 公式、Hubbard-I 无曲线的论证、反例；无自己的数值）。

2.10 GPT-6.1 Sol，`run_01`（30 分）

模型与结论。 这份答卷是对自己前一份（`run_02` 的辅助轨道构造）的撤回和重做：“The previous auxiliary-pole construction is withdrawn as a solution to the microscopic single-orbital task. This reanalysis uses only the four physical states of one spinful orbital at each site.”它做了三件事：(1) 8/10 格点单轨道 Hubbard 的 ED，排斥 $U = 11.49$ 或吸引 $U = -11.45$ 都能匹配 8.0 的能隙，但六张 STS 的 RMS 0.15–0.20（图 19）；(2) 10 自旋环面的动力学自旋响应：排斥 Hubbard 的 $J_1 = 0.346$ 给 $T = 0.447$ 处 $R/T \approx 6.7$，数据 3.4×10^{-5}，“even a free overall amplitude gives $\chi^2 \approx 244$ for 17 degrees of freedom”；(3) 3×2 开放团簇的 Kubo 电导。结论：“The main result is a failure to establish a joint fit, not a proof that no single-orbital theory can work.”

评判。 这是一份严谨的否定结果：它用物理的自旋算符和电流算符证明了单轨道 Hubbard 模型（两种符号）都不能同时解释 STS、NMR 和输运。但它的问题设定——“One site per primitive in-plane cell; no independent auxiliary electron orbital”——把能救它的那个自由度（第二层）明确排除了，而它撤回的辅助轨道 f 恰恰是离第二层最近的东西。它没有相图、没有参数、没有预测；ARPES 是 10 格点团簇的基准图；第 5 题给出团簇动量上精确的 $G(0)$（$+0.088, +0.058, -0.049, -0.124$）和两种嵌入下的份额 0.517/0.524，并正确说明连续插值不唯一。附带的 `audit_summary.txt` 对费米子符号、和规则、Lanczos 收敛做了独立审计，还讨论了 BCS 态中正常分量零点与 Nambu 矩阵零点的区别——内容正确，与题目无关。

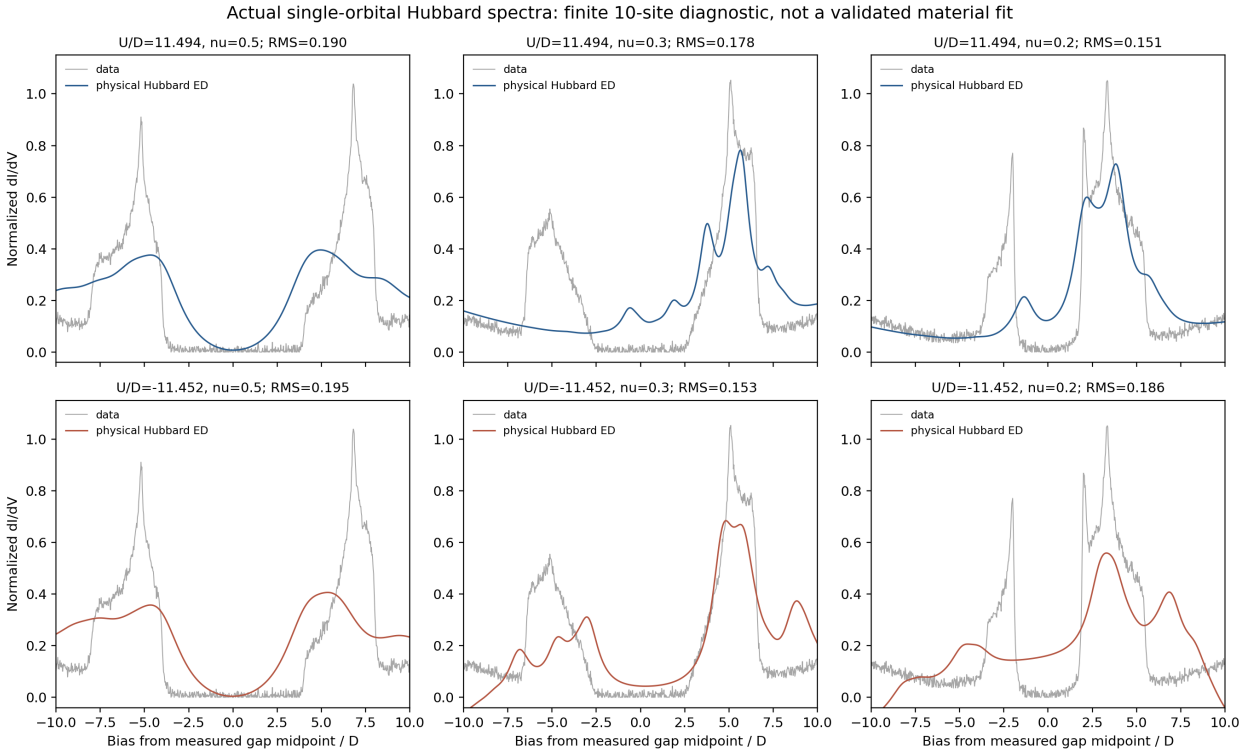


图 19: Sol `run_01`：10 格点单轨道 Hubbard ED（排斥上排、吸引下排）对六张 STS，RMS 0.15–0.20。

逐题评分。 1 题 4/20；2 题 3/20；3 题 7/20（自旋与输运的定量否证有价值）；4 题 5/20；5 题 11/20（团簇精确 $G(0)$、嵌入不唯一性；无承诺值）。

总评。　十一份里最“科学”的一份否定结果，也是最彻底的一份不作答。它在轨迹里花了大量计算证明“不是这个”，却没有花一步去问“那是什么”。

3 结语：这批答卷说明了什么

3.1 分数的分布是由一个决定造成的

十一份答卷在动力学参数、能标读取、BCS 拟合上几乎没有差别，分数却从 30 到 91。把分数排开来看，它们分成三档，三档的分界不是能力，而是在一个具体的判断点上做了什么：面对“面内一个位点、半填充、完全对称、有能隙”这组条件，是否承认一个原胞里必须有两个位点。承认的（Opus `run_01`、`run_03`）得 83–91；不承认但仍给出一个单层模型的（Fable 三份、Opus `run_02`）得 49–57；不作判断的（OpenAI 五份）得 30–47。第二档和第三档之间差的是“肯不肯给一个可证伪的模型”，第一档和第二档之间差的是“肯不肯在证据面前换模型”。

值得注意的是，这个判断不需要新知识。LSM 定理所有答卷都知道（八份写了出来），双层单态的物理四份写了出来（两份 Opus、Astra `run_01`、Sol `run_02`），Astra `run_01` 甚至搜到了出题人的文章。缺的是把“如果原胞只有一个位点则必须有拓扑序或破缺”这个条件句，和“拓扑序的能标不可能是 5.5、破缺已被衍射和 NMR 排除”这两个事实合起来，得出“所以原胞不止一个位点”。Opus `run_01` 的轨迹里这一步只有一句话，但它前面有三轮 ED 把单层的两种可能都定量地否定了，后面有一轮 ED 把双层定量地肯定了。它是先把自己逼到墙角，再转身。

3.2 保守是这批模型的默认姿态

OpenAI 的五份答卷有一个共同的修辞：每一个物理陈述后面跟一句“this is a modeling choice, not a measured value”“this is not a deduction”“these are counterexamples, not predictions”。它们不是不会，而是把“不能从数据唯一推出”当作了“不应该说”。Astra `run_01` 写出了正确的哈密顿量，Sol `run_02` 找到了题目的两处错误，Sol `run_01` 用自旋团簇定量否定了排斥 Hubbard——这些都是有相当水平的工作，但在题目要求“最可信的理论”时，它们把“可信”读成了“可证明”。信息不完全时，它们的策略是收缩到可证明的集合，而不是在可信的集合里选一个最可能的、然后说明它会被什么证伪。

Anthropic 的答卷没有这个问题，但有另一个：它们在选定模型以后不太愿意放弃。Fable `run_01` 做完单层 ED 发现掺杂能隙差一倍，加了一个随掺杂变的 U_{eff}；Opus `run_02` 列了四条自己模型的致命问题，仍然交了这个模型；Fable `run_02` 为 5.5 的自旋能隙发明了一个 (π,π) 形状因子机制。这是另一种保守：守住第一个假设。Opus `run_01` 之所以胜出，是它既敢选，也敢换。

3.3 “知道 SMG”和“推出双层”是两件事

出题人问的“AI 怎么会知道 SMG”，答案是训练语料里有这些 arXiv 文章，模型在数据特征（半宽平移副本、rung 单态、层间交换、掺杂后 BEC 型超导）足够独特时能把它和那一小簇文献对上，不需要检索。但这批答卷同时说明，知道名字既不充分也不必要：Opus `run_01` 没提 SMG 却推出了双层并算到了最接近精确解的结果；Opus `run_03` 提了 SMG、参数最准，但计算停在领头阶，第 5 题的符号反了；Astra `run_01` 搜索词里就有“symmetric mass generation bilayer”，报告里引了文献，结论仍是“双层是假设”。对出题而言，这意味着文献被模型看过并不自动泄露答案——把“对上文献”变成“确定模型”的那一步，是模型自己的推理，而且大多数答卷没有迈出去。

3.4 真正算过的答卷彼此一致，没算过的答卷彼此分歧

第 5 题的数值从 0.035 散到 0.855，看起来像一道没有稳定答案的题。但把答卷按“有没有做多体数值”分开，就能看出结构：Opus `run_01` 的 16 格点 CPT/ED 给 0.855，出题方的 3×3 团簇 ED 给 0.82–0.87，两者的 $G(\Gamma,0)$、$G(M,0)$ 几乎相同；而所有停在两极拟合的答卷——无论拟合多精细——都得到 Γ 侧 $\mathrm{Re}\,G<0$，份额在 0 到 0.31 之间。差别来自领头阶形式强加的对称性（两极关于带中心对称、残差反对称），它把零点钉在带中心等高线上，而真实的两条带宽度不同、残差不反对称。这告诉我们两件事：一是“拟合得好”不等于“谱是对的”，局域 DOS 对残差的 k 依赖几乎没有约束，Astra 和 Sol 关于不唯一性的数学论证是对的；二是解决不唯一性的办法不是放弃，而是去解那个哈密顿量——一旦模型定了，谱就定了，不唯一性就消失了。Opus `run_01` 花了其他答卷四到六倍的计算资源，这些资源主要用在这里。

3.5 答卷反过来纠正了题目

这批答卷暴露了题目的四处问题，都已修正：(1) $T_c(0.2)=1.11D$ 超过二维刚度上界（Sol `run_02` 明确、四份隐含）；(2) 图 (c) 用正常态 μ 画 BCS 谱，粒子数方程给 0.256（Sol `run_02`、Astra `run_01`）；(3) $\nu\approx0.2$ 的 Hebel–Slichter 峰与 $T_{\mathrm{MF}}=1.0$ 不相容；(4) 图 (a) 的领头阶谱比模型的精确谱宽、能隙小、残差结构反向（Opus `run_01` 的 CPT 曲线和 `run_03` 的高阶估计都指向这一点）。此外，三份单层吸引 U 答卷用“序在测量窗口之下”绕开 LSM，促使题目加了 $0.05D$ 那一句。一道“出给 AI 做”的题，最有效的审稿人是做得最好的那几份 AI 答卷；它们不同意数据的地方，多半是数据的错。

3.6 对出题和评分的启示

第一，区分度来自需要决定的考点，不来自需要计算的考点。t、t'、Δ、T_c 所有模型都会；LSM $\Rightarrow$ 双层只有最强模型的三分之一次数会。题目如果想测“在信息不完全时敢不敢下结论”，就应该像这道题一样，把一个只能用排除法得到的结构性结论设成关键一步，并在题面里把绕路的出口一个个堵上（$0.05D$ 句子就是堵出口）。

第二，评分要能区分“不作答”和“答错”。Astra 的反例、Sol 的审计都是正确的物理，但不是答案；把它们和 Fable 的错误模型放在同一分数段，是因为 rubric 按“给出可证伪的内容”给分，而不按“没说错话”给分。这个取向应该保留，否则会奖励回避。

第三，对残差敏感的数值题（第 5 题）要用自洽性和符号来评分，而不是用一个数。本报告完成后，题面的第 5 题已据此改写（TASK.md 修订 (c)）：去掉了“has a surface of zeros”“disperses relative to the two bands”“changes from 1 to 0”“whether it equals ν and why”这些告诉解题者答案长什么样的提示；要求报告沿路径的变号能量 $\omega_0(k)$（“if there is one”）、份额随 ω_r 的扫描、$\mathrm{Re}\,G(k,0)$ 在 $(0,0)$ 和 $(1/2,1/2)$ 的符号，并列出三个高对称点的极点和残差，供评分人一行算出符号核对。符号是新的甄别点：生成谱在 $(0,0)$ 处 $\mathrm{Re}\,G=+0.024$，removal 极点重（0.50）而远（-7.3），addition 极点轻（0.28）而近（$+4.3$），二者几乎抵消，符号由残差的高阶 k 依赖决定；所有停在两极拟合的答卷都得到相反的符号，而两份真正解了模型的计算（3×3 ED 和 16 格点 CPT/ED）一致。新的 20 分分配：零点带 4、扫描曲线 3、自洽性 3、两个符号 3、$\omega_r=0$ 的数值按计算层级分档 4、与 ν 的比较 3。按这个 rubric 回评这十一份，解了模型的两份仍在 17–20，领头阶两极答案降到 10–12，Hubbard-I“无曲线”答案约 9，只给反例的答案约 6——区分度回来了，而每一项都不依赖

一个在 0.03 和 0.9 之间摆动的数。

第四，最强的答卷需要最多的计算。Opus `run_01` 的 API 时间是 2.4 小时、费用 175 美元，其余在 28–46 美元之间。它的优势不在于它知道更多，而在于它把“知道”变成了“算过”。如果评测预算把计算压到几十美元以内，这道题测到的将主要是模型敢不敢猜，而不是能不能算；两者都值得测，但要知道测的是哪一个。